



UNIVERSIDADE DA CORUÑA

Aprendizaje Basado en Kernels y Comparación de Clasificadores

Inteligencia Computacional para Bioinformática

Práctica 3



Autores:

Antía Dorado Valín
Oussama El Khatib
Pablo Torreira Pardo

A Coruña, 27 de mayo 2025

Índice

Índice de figuras	III
Índice de tablas	III
1 Introducción	1
2 Objetivos	1
3 Material y Métodos	3
3.1 Material	3
3.1.1 Datos	3
3.1.2 Software y bibliotecas	5
3.2 Métodos	5
3.2.1 Modelado y validación	5
4 Metodología	9
4.1 Análisis exploratorio	9
4.2 Preparación de los datos	9
4.3 Selección y validación del modelo	9
4.4 Selección del mejor modelo de clasificación	10
4.5 Entrenamiento final	10
5 Iris dataset	11
5.1 Fase 0: Exploración inicial de los datos	11
5.1.1 Distribución de las variables	11
5.1.2 Matriz de correlación	11
5.2 Fase 1: Preprocesado de datos	12
5.2.1 Datos atípicos	12
5.2.2 Normalización	12
5.3 Fase 2: Aprendizaje	12
5.3.1 Configuración del método de aprendizaje	12
5.3.2 Selección del método de estimación del error real	13
5.3.3 Elección de las métricas de evaluación	13
5.3.4 Entrenamiento y obtención de resultados	13
5.4 Fase 3: Análisis de resultados y comparación de modelos	14
5.4.1 Resultados de clasificación	14
5.4.2 Comparación entre modelos	15
5.4.3 Selección del mejor modelo para la resolución del problema	16
6 QSAR biodegradation dataset	16
6.1 Fase 0: Exploración inicial de los datos	16
6.1.1 Distribución de las variables	16
6.1.2 Matriz de correlación	18
6.2 Fase 1: Preprocesado de datos	18
6.2.1 Datos atípicos	18
6.2.2 Normalización	18
6.3 Fase 2: Aprendizaje	19
6.3.1 Configuración del método de aprendizaje	19
6.3.2 Selección del método de estimación del error real	19
6.3.3 Elección de las métricas de evaluación	19
6.3.4 Entrenamiento y obtención de resultados	19
6.4 Fase 3: Análisis de resultados y comparación de modelos	20
6.4.1 Resultados de clasificación	20
6.4.2 Comparación entre modelos	21
6.4.3 Selección del mejor modelo para la resolución del problema	22
7 Henon dataset	22
7.1 Fase 0: Exploración inicial de los datos	22
7.1.1 Distribución de las variables	22
7.2 Fase 1: Preprocesado de datos	22
7.2.1 Generación de conjuntos de datos	22
7.3 Fase 2: Aprendizaje	23
7.3.1 Configuración del método de aprendizaje	23
7.3.2 Selección del método de estimación del error real	23
7.3.3 Elección de las métricas de evaluación	23
7.3.4 Entrenamiento y obtención de resultados	23
7.4 Fase 3: Análisis de resultados y comparación de modelos	23
7.4.1 Resultados de regresión	23
7.4.2 Comparación entre los dos mejores modelos SVM	26

7.4.3	Selección del mejor modelo	27
8	Discusión y Conclusiones	28
8.1	Discusión	28
8.2	Conclusiones	29

Índice de figuras

1	Leave-One-Out Cross-Validation (LOOCV)	6
2	K-Fold Cross-Validation	7
3	Diagramas de caja de las variables cuantitativas del dataset Iris.	11
4	Matriz de correlación entre las variables del dataset Iris.	12
5	Matrices de confusión obtenidas con LDA, QDA, Decision Tree y SVM utilizando LOOCV.	15
6	Diagramas de caja de las variables cuantitativas del dataset QSAR.	17
7	Histogramas de las variables cualitativas del dataset QSAR.	17
8	Matriz de correlaciones QSAR.	18
9	Comparaciones múltiples entre configuraciones de SVM para <i>F1-Score</i>	20
10	Comparaciones múltiples para Accuracy entre LDA, QDA, Árbol de Decisión y SVM	21
11	Comparaciones múltiples para F1-score entre LDA, QDA, Árbol de Decisión y SVM	21
12	Comparaciones múltiples para Recall entre LDA, QDA, Árbol de Decisión y SVM	22
13	Últimos 50 valores de la serie Henon.	22
14	Comparaciones múltiples para MSE en $d = 5$	24
15	Comparaciones múltiples para RMSE en $d = 5$	24
16	Comparaciones múltiples para MAE en $d = 5$	25
17	Comparaciones múltiples para MSE en $d = 10$	26
18	Comparaciones múltiples para RMSE en $d = 10$	26
19	Comparaciones múltiples para MAE en $d = 10$	26
20	Últimos 50 valores: Real vs. Predicho (SVM4, ventana 5)	27

Índice de tablas

1	Estadísticas descriptivas de las variables del dataset Iris.	11
2	Resultados de las configuraciones de SVM en el dataset Iris	14
3	Comparación de la <i>accuracy</i> media y desviación estándar entre modelos	16
4	Resultados de las configuraciones de SVM en el dataset QSAR	20
5	Estadísticas descriptivas de las 1500 muestras de la serie Henon	22
6	Dimensiones de los conjuntos de datos generados con ventanas de tamaño 5 y 10.	23
7	Resultados de las configuraciones de SVM en el dataset Henon ($d = 5$, sin normalización)	24
8	Resultados de las configuraciones de SVM en el dataset Henon ($d = 10$)	25

1 Introducción

El análisis de datos se ha consolidado como una herramienta esencial en la toma de decisiones basada en evidencia, especialmente en el ámbito de la clasificación y el reconocimiento de patrones. En este estudio, se emplean dos conjuntos de datos ampliamente utilizados en la literatura científica: el dataset Iris y el dataset QSAR biodegradation. Ambos permiten evaluar el rendimiento de distintos modelos de clasificación en contextos variados, desde problemas de biología hasta química ambiental.

El dataset Iris, introducido por Ronald Fisher en 1936, es un clásico en la evaluación de algoritmos de clasificación. Contiene 150 observaciones de tres especies de flores (Iris setosa, Iris versicolor e Iris virginica), descritas por cuatro características morfológicas: longitud y ancho de sépalos y pétalos. Su simplicidad y equilibrio lo convierten en un referente ideal para validar modelos estadísticos.

Por otro lado, el dataset QSAR biodegradation se centra en predecir la biodegradabilidad de compuestos químicos. Contiene 41 descriptores moleculares que representan propiedades físicas, químicas y estructurales de 1055 compuestos, junto con una variable categórica que indica si el compuesto es biodegradable (RB) o no biodegradable (NRB). Este conjunto de datos permite evaluar el rendimiento de los modelos de clasificación en un contexto químico, con desafíos adicionales debido a su complejidad y mayor número de variables.

En el contexto de este análisis, la clasificación se convierte en un elemento fundamental para evaluar la capacidad de los modelos de diferenciar entre clases de manera precisa y consistente. Esto implica no solo identificar las características más relevantes de cada conjunto de datos, sino también aplicar métodos de validación robustos que permitan obtener una estimación confiable del rendimiento del modelo.

Además, esta práctica incluye una segunda parte centrada en la regresión, utilizando conjuntos generados a partir de la serie de Henon. En este caso, se aplican técnicas basadas en aprendizaje por kernels para resolver un problema de predicción, entrenando y comparando diferentes configuraciones de máquinas de vectores soporte (SVM) al modificar parámetros como el tipo de kernel y el valor de C. Este bloque complementa el análisis de clasificación, permitiendo explorar el ajuste de modelos a problemas continuos y evaluando su rendimiento mediante medidas de error específicas para regresión, siempre bajo un diseño experimental riguroso.

2 Objetivos

El objetivo principal de esta práctica es comparar el rendimiento de diferentes modelos de clasificación (LDA, QDA, Árboles de Decisión y SVM en múltiples configuraciones) sobre los conjuntos de datos *Iris* y *QSAR biodegradation*. Para ello:

- Se entrenan **nueve versiones de SVM** por conjunto de datos, combinando tres funciones kernel (lineal, polinómico, gaussiano) con tres valores del parámetro C.
- Se evalúan cinco métricas de rendimiento: *Accuracy*, *Recall*, *Precision*, *Specificity* y *F1-score*.
- Se aplican **métodos de validación cruzada** adecuados a la naturaleza de cada conjunto,

repitiendo los experimentos tres veces para asegurar robustez.

- Se realizan **comparaciones estadísticas** (Kruskal-Wallis y correcciones de Bonferroni) para determinar la existencia de diferencias significativas entre modelos.
- Se selecciona el **modelo más adecuado** para cada problema de clasificación, considerando tanto el rendimiento como la simplicidad computacional.

Adicionalmente, en la segunda parte de la práctica se aborda un problema de regresión utilizando datos generados a partir de la serie de Henon, considerando dos conjuntos con tamaños de ventana distintos (5 y 10). Para ello:

- Se entrenan varias configuraciones de **SVM para regresión**, modificando los hiperparámetros (kernel y parámetro C) y utilizando **validación cruzada de 10 folds** con tres repeticiones.
- Se evalúa el rendimiento de los modelos mediante métricas específicas de regresión: MSE (Mean Squared Error), RMSE (Root Mean Squared Error) y MAE (Mean Absolute Error).
- Se realizan **análisis estadísticos para comparar los modelos** (ANOVA y comparaciones múltiples con corrección de Bonferroni), identificando diferencias significativas entre las configuraciones evaluadas.
- Se comparan los mejores modelos obtenidos con distinto tamaño de ventana mediante el test de **Wilcoxon** para contrastar la influencia del tamaño de ventana en la capacidad predictiva.
- Se selecciona el **modelo final en función del rendimiento** y la estabilidad, destacando la mejor configuración para la predicción de series temporales.

3 Material y Métodos

3.1. Material

3.1.1. Datos

Este estudio utiliza dos conjuntos de datos del UCI Machine Learning Repository: el dataset **Iris** y el dataset **QSAR biodegradation**. Ambos permiten evaluar el rendimiento de distintos modelos de clasificación en contextos de biología y química ambiental.

El dataset **Iris** contiene 150 observaciones de tres especies de flores (*Iris setosa*, *Iris versicolor* e *Iris virginica*), descritas por cuatro variables cuantitativas:

- **SepalLength**: Longitud del sépalo (cm).
- **SepalWidth**: Ancho del sépalo (cm).
- **PetalLength**: Longitud del pétalo (cm).
- **PetalWidth**: Ancho del pétalo (cm).

El dataset **QSAR biodegradation** contiene información sobre 1055 compuestos químicos, descritos mediante 41 descriptores moleculares y clasificados en función de su biodegradabilidad en el medio ambiente:

- **SpMax_L**: Valor propio principal de la matriz de Laplace.
- **J_Dz(e)**: Índice tipo Balaban de la matriz de Barysz ponderado por la electronegatividad de Sanderson.
- **nHM**: Número de átomos pesados.
- **F01[N-N]**: Frecuencia de N-N a una distancia topológica de 1.
- **F04[C-N]**: Frecuencia de C-N a una distancia topológica de 4.
- **NssssC**: Número de átomos de tipo ssssC.
- **nCb-**: Número de carbonos (sp²) bencénicos sustituidos.
- **C %**: Porcentaje de átomos de carbono.
- **nCp**: Número de carbonos primarios terminales (sp³).
- **nO**: Número de átomos de oxígeno.
- **F03[C-N]**: Frecuencia de C-N a una distancia topológica de 3.
- **SdssC**: Suma de los estados E de dssC.
- **HyWi_B(m)**: Índice tipo Hyper-Wiener (función logarítmica) de la matriz de Burden ponderado por la masa.
- **LOC**: Índice de centrado de ramificación.
- **SM6_L**: Momento espectral de orden 6 de la matriz de Laplace.
- **F03[C-O]**: Frecuencia de C-O a una distancia topológica de 3.

- **Me**: Media de la electronegatividad atómica de Sanderson (escalada en el átomo de carbono).
- **Mi**: Media del primer potencial de ionización (escalado en el átomo de carbono).
- **nN-N**: Número de hidrazinas de N.
- **nArNO2**: Número de grupos nitro (aromáticos).
- **nCRX3**: Número de CRX3.
- **SpPosA_B(p)**: Suma espectral positiva normalizada de la matriz de Burden ponderada por la polarizabilidad.
- **nCIR**: Número de circuitos.
- **B01[C-Br]**: Presencia/ausencia de C-Br a una distancia topológica de 1.
- **B03[C-Cl]**: Presencia/ausencia de C-Cl a una distancia topológica de 3.
- **N-073**: Ar₂NH / Ar₃N / Ar₂N-Al / R..N..R.
- **SpMax_A**: Valor propio principal de la matriz de adyacencia (Índice Lovasz-Pelikan).
- **Psi_i_1d**: Índice de pseudoconectividad de estado intrínseco - tipo 1d.
- **B04[C-Br]**: Presencia/ausencia de C-Br a una distancia topológica de 4.
- **SdO**: Suma de los estados E de dO.
- **TI2_L**: Segundo índice de Mohar de la matriz de Laplace.
- **nCrt**: Número de carbonos terciarios en anillos (sp³).
- **C-026**: R-CX-R.
- **F02[C-N]**: Frecuencia de C-N a una distancia topológica de 2.
- **nHDon**: Número de átomos donadores de enlaces de hidrógeno (N y O).
- **SpMax_B(m)**: Valor propio principal de la matriz de Burden ponderado por la masa.
- **Psi_i_A**: Índice de pseudoconectividad de estado intrínseco - tipo S promedio.
- **nN**: Número de átomos de nitrógeno.
- **SM6_B(m)**: Momento espectral de orden 6 de la matriz de Burden ponderado por la masa.
- **nArCOOR**: Número de ésteres (aromáticos).
- **nX**: Número de átomos de halógenos.
- **experimental class**: Clase experimental (biodegradable listo (RB) y no biodegradable listo (NRB)).

Los datos fueron preprocesados para eliminar valores atípicos y garantizar la consistencia de las variables antes de aplicar los modelos de clasificación.

Además, se utiliza la **serie de Henon**, que es una secuencia temporal generada mediante un sistema dinámico no lineal. De esta serie se extraen 1500 muestras consecutivas elegidas aleatoriamente, que se transforman en conjuntos de regresión utilizando ventanas deslizantes de dos tamaños distintos:

- **Conjunto 1:** ventana de tamaño 5, generando variables predictoras a partir de las cinco observaciones anteriores.
- **Conjunto 2:** ventana de tamaño 10, generando variables predictoras a partir de las diez observaciones anteriores.

El objetivo con los datos Henon es evaluar el rendimiento de los modelos de regresión SVM al predecir la siguiente observación en la serie, comparando configuraciones de kernel y parámetros, así como el impacto del tamaño de la ventana en la calidad de la predicción.

3.1.2. Software y bibliotecas

El análisis y la implementación de los modelos fueron realizados en el entorno **MATLAB**, utilizando herramientas específicas para el modelado y la evaluación de los clasificadores:

- **fitcdiscr:** para entrenar modelos de clasificación basados en discriminante lineal de Fisher (LDA) y discriminante cuadrático (QDA).
- **fitctree:** para el entrenamiento de árboles de decisión, explorando distintas configuraciones de profundidad y tamaño de nodo.
- **fitsvm** y **templateSVM:** para entrenar máquinas de vectores soporte (SVM), combinando diferentes funciones kernel (*lineal*, *polinómica* y *gaussiana*) y valores del parámetro de penalización C .
- **fitrsvm:** para entrenar modelos de regresión SVM sobre los conjuntos generados a partir de la serie de Henon, evaluando múltiples configuraciones de kernel y valores de C .
- **cvpartition:** para la partición de los datos mediante validación cruzada, tanto en modalidad *Leave-One-Out* (LOOCV) como en *K-fold estratificado*.
- **confusionmat** y **confusionchart:** para obtener y visualizar las matrices de confusión en cada iteración de validación.
- **boxplot**, **imagesc**, **histogram**, **scatter:** para el análisis exploratorio y representación gráfica de los datos.
- **kruskalwallis**, **multcompare**, **anova1**, **signrank:** para la realización de comparaciones estadísticas no paramétricas y análisis post hoc con corrección de Bonferroni o Wilcoxon.

3.2. Métodos

3.2.1. Modelado y validación

Se aplicaron cuatro modelos de **clasificación**:

- **Discriminante Lineal de Fisher (LDA):** Modelo que asume distribuciones gaussianas con la misma matriz de covarianza para todas las clases y busca maximizar la separación entre ellas mediante una frontera lineal. En este caso, se utilizó su configuración estándar, sin ajuste adicional de hiperparámetros.
- **Discriminante Cuadrático (QDA):** Similar a LDA, pero permite que cada clase tenga su propia matriz de covarianza, generando fronteras de decisión más flexibles. Se probó también en su variante pseudo-cuadrática, que introduce regularización para estabilizar la estimación de covarianzas en conjuntos de datos pequeños.

- **Árbol de Decisión:** Modelo jerárquico que divide los datos en subconjuntos según reglas de decisión en cada nodo. Se exploraron distintas combinaciones de parámetros clave, como la profundidad máxima (*MaxDepth*), el tamaño mínimo de las hojas (*MinLeafSize*) y el tamaño mínimo del nodo padre (*MinParentSize*), buscando el mejor equilibrio entre precisión y simplicidad.
- **Máquinas de Vectores Soporte (SVM):** Se evaluaron nueve configuraciones, combinando tres funciones *kernel* (*lineal*, *polinómica*, *gaussiana*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. En el caso del dataset Iris, se utilizó codificación *one-vs-one* para abordar la clasificación multiclase.

En la parte de **regresión**, se aplicaron modelos SVM de regresión sobre los conjuntos generados a partir de la serie de Henon. Se utilizaron configuraciones combinando diferentes kernels (lineal, polinómico, gaussiano) y valores del parámetro C, aplicando validación cruzada de 10 folds repetida tres veces.

Para evaluar el rendimiento de los modelos, se utilizaron dos estrategias de validación cruzada:

- **Leave-One-Out Cross-Validation (LOOCV)** en el dataset Iris, dejando una observación para prueba en cada iteración. Esto se ha decidido teniendo en cuenta el tamaño muestral reducido (150 muestras). Este procedimiento se repitió tres veces, barajando los resultados tras cada iteración.




Figura 1: Leave-One-Out Cross-Validation (LOOCV)

El método se basa en realizar tantos pares de conjuntos train-test como muestras tengamos. En cada iteración se 'deja fuera' una de las muestras (que será utilizada para realizar la prueba) y se entrena con el resto de muestras. Repitiendo este procedimiento hasta que cada muestra ha sido utilizada como prueba una vez.

- **Validación K-Fold** ($K = 10$) en los datasets QSAR biodegradation y Henon, dividiendo el conjunto en 10 particiones y utilizando 9 para entrenamiento en cada iteración. Se decidió utilizar este método teniendo en cuenta que estos datasets presentan un mayor número de muestras (1055 y 1500 muestras respectivamente). Cada evaluación se repitió tres veces para garantizar la estabilidad de los resultados.



Figura 2: K-Fold Cross-Validation

Es una técnica de validación cruzada en la que el dataset se divide en K subconjuntos (o folds) de tamaño similar. En cada iteración, uno de estos folds se usa como conjunto de prueba, mientras que los K-1 restantes se utilizan para entrenar el modelo. Este proceso se repite K veces, asegurando que cada muestra se utilice como prueba una vez.

Para llevar a cabo las comparaciones entre modelos se utilizaron las siguientes pruebas estadísticas:

- **Kruskal-Wallis:** es una prueba no paramétrica que compara tres o más grupos independientes para determinar si provienen de la misma distribución. Es una extensión del test de Mann-Whitney y se usa cuando los datos no siguen una distribución normal. Su hipótesis nula establece que las medianas de los grupos son iguales.
- **Bonferroni:** es un método para ajustar el nivel de significancia en pruebas múltiples, reduciendo el riesgo de error tipo I (falsos positivos). Se calcula dividiendo el nivel de significancia entre el número de comparaciones realizadas. Se usa en comparaciones post hoc tras un ANOVA o Kruskal-Wallis.
- **ANOVA de un factor:** Prueba paramétrica que evalúa si existen diferencias significativas entre las medias de tres o más grupos independientes. Su hipótesis nula plantea que todas las medias poblacionales son iguales. Se emplea para analizar las métricas de error en los modelos de regresión.
- **Test de Wilcoxon para muestras apareadas (signrank):** Prueba no paramétrica utilizada para comparar dos muestras relacionadas, evaluando si sus medianas difieren significativamente. Se aplicó para comparar los modelos seleccionados entrenados con distintos tamaños de ventana en la serie de Henon.

La evaluación de los modelos se realizó mediante las siguientes métricas :

- **Precisión (Accuracy):** Proporción de clasificaciones correctas sobre el total de observaciones.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Sensibilidad (Recall)**: Capacidad del modelo para identificar correctamente los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **Especificidad (Specificity)**: Capacidad del modelo para identificar correctamente los casos negativos.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **Precisión Positiva (Precision)**: Proporción de predicciones positivas correctas.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **F1-score**: Media armónica entre precisión y sensibilidad.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Error cuadrático medio (MSE)**: Promedio de los cuadrados de las diferencias entre los valores predichos y los valores reales.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Raíz del error cuadrático medio (RMSE)**: Raíz cuadrada del MSE, proporciona una interpretación en las mismas unidades que la variable objetivo.

$$RMSE = \sqrt{MSE}$$

- **Error absoluto medio (MAE)**: Promedio de las diferencias absolutas entre los valores predichos y los reales.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4 Metodología

Este estudio empleó un enfoque sistemático para resolver los problemas de clasificación en los datasets *Iris* y *QSAR biodegradation*, y de regresión en los conjuntos generados a partir de la serie de Henon. Se inició con la limpieza y preprocesamiento de los datos, seguido de un análisis exploratorio, la implementación de los modelos y la validación de los resultados.

4.1. Análisis exploratorio

Para comprender la estructura y relaciones de los datos, se realizó un análisis exploratorio mediante:

- Histogramas para visualizar la distribución de las variables.
- Diagramas de caja para detectar valores atípicos.
- Matriz de correlación para evaluar relaciones lineales entre variables.

La matriz de correlación se calculó utilizando el coeficiente de Pearson:

$$C_{ij} = \frac{\text{Cov}(X_i, X_j)}{\sigma_{X_i} \sigma_{X_j}},$$

donde:

- X_i, X_j son variables cuantitativas.
- $\text{Cov}(X_i, X_j)$ representa la covarianza entre X_i y X_j .
- $\sigma_{X_i}, \sigma_{X_j}$ son las desviaciones estándar.

Este análisis permitió detectar patrones en los datos y verificar la independencia de las variables predictoras.

4.2. Preparación de los datos

El proceso comenzó con la limpieza y transformación del conjunto de datos. Las variables fueron revisadas para asegurar su formato correcto según su naturaleza (numéricas o categóricas). Se eliminaron valores atípicos que podrían afectar el rendimiento de los modelos y se normalizaron las variables cuantitativas por el método Z-Score para evitar que diferencias en escala influyeran en la clasificación.

La normalización se realizó dentro de cada iteración de validación cruzada, asegurando que los datos de prueba no influyeran en el cálculo de los parámetros de normalización:

$$X_{\text{norm}} = \frac{X - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

donde μ_{train} y σ_{train} corresponden a la media y desviación estándar del conjunto de entrenamiento.

4.3. Selección y validación del modelo

Clasificación: El proceso de selección del modelo incluyó la comparación de los resultados obtenidos con LDA, QDA, Árboles de Decisión y las nueve configuraciones evaluadas de SVM. Para el dataset *Iris*, se aplicó validación cruzada Leave-One-Out (LOOCV), mientras que para

el dataset *QSAR biodegradation* se utilizó validación cruzada K-fold, permitiendo una evaluación más adecuada dada la mayor cantidad de observaciones. En el caso de las SVM, se implementó una estrategia basada en tres repeticiones de la validación seleccionada, agrupando posteriormente las predicciones en subconjuntos de igual tamaño para calcular métricas promedio por fold.

Regresión: En los conjuntos generados a partir de la serie de Henon, se entrenaron modelos de regresión SVM utilizando combinaciones de kernels (lineal, polinómico, gaussiano) y valores de C. Se aplicó validación cruzada de 10 folds repetida tres veces. Las predicciones se evaluaron mediante métricas específicas para regresión: MSE, RMSE y MAE. Los resultados se analizaron mediante ANOVA de un factor y comparaciones post hoc con Bonferroni. Se utilizó un ANOVA de un factor porque, al disponer de un tamaño muestral suficientemente grande (gracias a la validación cruzada de 10 folds repetida tres veces), se puede asumir que la distribución de las métricas promedio (MSE, RMSE y MAE) tiende a la normalidad, según establece el teorema del límite central. Esto justifica el uso de ANOVA, que requiere como supuesto fundamental que las medias de los grupos a comparar sigan aproximadamente una distribución normal. Además, se aplicó el test de Wilcoxon para comparar el rendimiento de los modelos seleccionados con diferentes tamaños de ventana.

4.4. Selección del mejor modelo de clasificación

Para cada modelo entrenado, se calcularon las métricas de evaluación correspondientes. En clasificación: Accuracy, Recall, Precision, Specificity y F1-score; en regresión: MSE, RMSE y MAE. En ambos casos, se aplicaron pruebas estadísticas (Kruskal-Wallis y ANOVA, según correspondiera) para evaluar la existencia de diferencias estadísticamente significativas entre modelos. Cuando fue necesario, se realizaron comparaciones múltiples mediante el método de Bonferroni. En el análisis de regresión, el test de Wilcoxon permitió evaluar diferencias entre los modelos seleccionados en función del tamaño de ventana. La selección final consideró rendimiento, simplicidad computacional y estabilidad ante variaciones en los datos.

4.5. Entrenamiento final

Finalmente, tras evaluar el rendimiento de los modelos con validación cruzada, se entrenó un modelo final utilizando el conjunto completo de datos para cada dataset. Este modelo optimizado busca aprovechar toda la información disponible y maximizar su capacidad predictiva en aplicaciones futuras.

5 Iris dataset

5.1. Fase 0: Exploración inicial de los datos

Para comprender la distribución de las variables en el dataset Iris, se realizó un análisis exploratorio que incluyó estadísticas descriptivas, diagramas de caja (para observar la distribución de los valores en cada variable) y una matriz de correlación.

Variable	NumMissing	Min	Median	Max	Mean
SepalLength	0	4.3	5.8	7.9	5.8433
SepalWidth	0	2.0	3.0	4.4	3.0540
PetalLength	0	1.0	4.35	6.9	3.7587
PetalWidth	0	0.1	1.3	2.5	1.1987

Cuadro 1: Estadísticas descriptivas de las variables del dataset Iris.

5.1.1. Distribución de las variables

Los diagramas de caja permiten identificar valores atípicos y analizar la distribución de cada variable en el dataset. En la Figura 3, se presentan los boxplots para las cuatro variables principales.




Figura 3: Diagramas de caja de las variables cuantitativas del dataset Iris.

En estos gráficos se observa que *SepalWidth* presenta valores atípicos, identificados como puntos fuera de los límites de los bigotes, lo que sugiere una posible dispersión mayor en esta variable.

5.1.2. Matriz de correlación

Para evaluar las relaciones entre las variables cuantitativas, se calculó la matriz de correlación de Pearson, presentada en la Figura 4.




Figura 4: Matriz de correlación entre las variables del dataset Iris.

La matriz de correlación indica una relación fuerte y positiva entre *SepalLength* y *PetalLength* ($r = 0,8718$), así como entre *PetalLength* y *PetalWidth* ($r = 0,9628$). En contraste, *SepalWidth* muestra correlaciones negativas con otras variables, sugiriendo que podría aportar información diferenciada en la clasificación.

5.2. Fase 1: Preprocesado de datos

5.2.1. Datos atípicos

En este caso hemos decidido no transformar los datos considerados atípicos de la variable *SepalWidth*, ya que consideramos que estos valores entran dentro de lo posible y no creemos que se deba a un error de toma de datos, ni que vaya a afectar negativamente a la clasificación (más bien, podría ser un aspecto clave para la clasificación).

5.2.2. Normalización

Las variables predictoras (*SepalLength*, *SepalWidth*, *PetalLength* y *PetalWidth*) fueron normalizadas para evitar que las diferencias de escala afectaran la clasificación.

Se realizó dentro de cada iteración de validación cruzada, asegurando que los datos de prueba no influyeran en el cálculo de los parámetros de normalización, posteriormente se aplicó dicha normalización a los datos de prueba de cada iteración.

5.3. Fase 2: Aprendizaje

En esta fase, se configuraron y entrenaron los modelos de Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA) y diferentes modelos de Árboles de Decisión en el dataset Iris, utilizando validación cruzada Leave-One-Out (LOOCV) para evaluar su rendimiento. Además, se incluyeron nueve configuraciones de máquinas de vectores soporte (SVM) para su comparación.

5.3.1. Configuración del método de aprendizaje

Para la clasificación de las especies de flores en el dataset Iris, se aplicaron los siguientes modelos:

- **LDA (Linear Discriminant Analysis)**: Se asume que las clases comparten la misma matriz de covarianza, generando fronteras de decisión lineales.
- **QDA (Quadratic Discriminant Analysis)**: Permite que cada clase tenga su propia matriz de covarianza, lo que posibilita fronteras de decisión curvas.
- **Árbol de Decisión**: modelo basado en una estructura jerárquica que divide los datos en subconjuntos según reglas de decisión en cada nodo. Se entrenaron diferentes modelos variando la profundidad del árbol, el tamaño mínimo de hoja (número mínimo de observaciones que debe contener un nodo hoja) y el tamaño mínimo del nodo padre (número mínimo de observaciones que debe tener un nodo antes de dividirse en nodos hijos).
- **SVM (Support Vector Machines)**: se evaluaron nueve configuraciones distintas, combinando tres funciones kernel (*lineal*, *gaussiana* y *polinómica*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. Para la clasificación multiclase se empleó la estrategia *one-vs-one*.

5.3.2. Selección del método de estimación del error real

Dado que el dataset Iris tiene un tamaño pequeño ($n = 150$), se utilizó **Leave-One-Out Cross-Validation (LOOCV)** como método de estimación del error real. Este enfoque entrena el modelo con $n - 1$ observaciones y prueba con la restante, repitiendo este proceso n veces.

Las ventajas de LOOCV incluyen:

- Maximiza el uso de los datos disponibles para entrenamiento.
- Proporciona una evaluación sin sesgo en datasets pequeños.
- Asegura que cada instancia sea utilizada como prueba en al menos una iteración.

En el caso de las SVM, se repitió el procedimiento de LOOCV tres veces. Las predicciones obtenidas en cada repetición fueron barajadas y organizadas en 10 subconjuntos de igual tamaño, con el fin de calcular métricas por fold y permitir comparaciones estadísticas entre modelos.

5.3.3. Elección de las métricas de evaluación

Para comparar el rendimiento de LDA, QDA, Árboles de Decisión y SVM, se utilizaron las métricas especificadas en el subapartado 3.2.1.

En cuanto a la importancia que presenta cada métrica para el problema concreto, se consideró que la **Accuracy** era la más adecuada para elegir el mejor modelo. Esta elección se debe a la necesidad de clasificar correctamente, sin preferencia por ninguna de las clases en particular.

5.3.4. Entrenamiento y obtención de resultados

Los modelos LDA, QDA, Árboles de Decisión y SVM fueron entrenados y evaluados utilizando LOOCV de la siguiente manera:

1. Se separó una observación para prueba y se entrenó el modelo con las restantes $n - 1$.
2. Se registró la predicción para la muestra de prueba.
3. Se repitió el proceso para cada una de las n observaciones.

4. En el caso de las SVM, este procedimiento se repitió tres veces con diferentes semillas, y las predicciones resultantes se barajaron y dividieron en subconjuntos para el análisis estadístico.
5. Se construyeron las matrices de confusión y se calcularon las métricas de evaluación para cada modelo.

5.4. Fase 3: Análisis de resultados y comparación de modelos

En esta sección se presentan los resultados obtenidos para los modelos Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), Árboles de Decisión y Support Vector Machine (SVM) en el dataset Iris. Se analizan las métricas de evaluación, se comparan los modelos mediante pruebas estadísticas y se selecciona el mejor modelo para la clasificación.

La *accuracy* se eligió como métrica principal de comparación porque resume de forma directa la proporción total de clasificaciones correctas sobre el conjunto de datos, ofreciendo una visión global del rendimiento de cada modelo. En este caso, dado que el conjunto Iris presenta clases balanceadas y bien definidas, la *accuracy* proporciona una medida adecuada y representativa del desempeño de los clasificadores, evitando la necesidad de métricas adicionales como el *recall* o la *precision*, que son especialmente relevantes en escenarios con clases desbalanceadas.

5.4.1. Resultados de clasificación

Además de los modelos LDA, QDA y Árboles de Decisión evaluados con su configuración más simple, se entrenaron nueve modelos SVM combinando tres funciones *kernel* (*lineal*, *gaussiana* y *polinómica*) con tres valores del parámetro $C = \{1, 3, 5\}$.

Las métricas de rendimiento para los modelos SVM fueron calculadas tras aplicar validación cruzada LOOCV con tres repeticiones. Los resultados obtenidos se barajaron y agruparon en 10 subconjuntos para calcular medias y desviaciones estándar de forma coherente con los modelos anteriores. A continuación, se muestra el resumen de métricas globales para los modelos SVM:

Cuadro 2: Resultados de las configuraciones de SVM en el dataset Iris

Parámetros			Métricas				
Modelo	Kernel	C	Accuracy	Recall	Precision	Specificity	F1-score
SVM 1	lineal	1	$0.969 \pm 0.00 \times 10^{+00}$	$0.954 \pm 9.80 \times 10^{-04}$	$0.954 \pm 9.02 \times 10^{-04}$	$0.976 \pm 1.53 \times 10^{-04}$	$0.950 \pm 3.25 \times 10^{-03}$
SVM 2	lineal	3	$0.978 \pm 0.00 \times 10^{+00}$	$0.963 \pm 5.03 \times 10^{-03}$	$0.974 \pm 1.64 \times 10^{-03}$	$0.982 \pm 5.71 \times 10^{-04}$	$0.965 \pm 2.52 \times 10^{-03}$
SVM 3	lineal	5	$0.978 \pm 0.00 \times 10^{+00}$	$0.965 \pm 6.56 \times 10^{-03}$	$0.968 \pm 1.03 \times 10^{-02}$	$0.983 \pm 2.00 \times 10^{-03}$	$0.961 \pm 4.50 \times 10^{-03}$
SVM 4	gaussiana	1	$0.969 \pm 0.00 \times 10^{+00}$	$0.949 \pm 1.07 \times 10^{-02}$	$0.958 \pm 4.06 \times 10^{-03}$	$0.975 \pm 2.59 \times 10^{-03}$	$0.948 \pm 4.43 \times 10^{-03}$
SVM 5	gaussiana	3	$0.960 \pm 1.36 \times 10^{-16}$	$0.945 \pm 3.99 \times 10^{-03}$	$0.945 \pm 1.94 \times 10^{-03}$	$0.970 \pm 1.90 \times 10^{-03}$	$0.941 \pm 3.80 \times 10^{-03}$
SVM 6	gaussiana	5	$0.960 \pm 1.57 \times 10^{-16}$	$0.946 \pm 4.05 \times 10^{-03}$	$0.944 \pm 2.98 \times 10^{-03}$	$0.970 \pm 1.51 \times 10^{-03}$	$0.941 \pm 3.33 \times 10^{-03}$
SVM 7	polinómica	1	$0.964 \pm 0.00 \times 10^{+00}$	$0.945 \pm 5.24 \times 10^{-03}$	$0.942 \pm 7.97 \times 10^{-03}$	$0.975 \pm 1.16 \times 10^{-03}$	$0.937 \pm 5.25 \times 10^{-03}$
SVM 8	polinómica	3	$0.960 \pm 1.36 \times 10^{-16}$	$0.942 \pm 3.22 \times 10^{-03}$	$0.940 \pm 1.12 \times 10^{-02}$	$0.971 \pm 1.36 \times 10^{-03}$	$0.934 \pm 5.65 \times 10^{-03}$
SVM 9	polinómica	5	$0.964 \pm 7.85 \times 10^{-17}$	$0.949 \pm 9.05 \times 10^{-03}$	$0.953 \pm 6.23 \times 10^{-03}$	$0.973 \pm 8.62 \times 10^{-04}$	$0.945 \pm 7.36 \times 10^{-03}$

Los resultados muestran que todas las configuraciones de SVM presentan rendimientos elevados y consistentes, siendo especialmente destacables las combinaciones con kernel lineal y $C = 3$ o $C = 5$, que obtienen las mejores puntuaciones en la mayoría de métricas. Las configuraciones con kernel polinómico y gaussiano también ofrecen buenos resultados, aunque ligeramente inferiores.

Se ha comprobado si existen diferencias estadísticamente significativas entre las distintas configuraciones de SVM en términos de *accuracy*, aplicando el test no paramétrico de Kruskal-Wallis sobre las puntuaciones obtenidas tras el reagrupamiento en folds. El resultado muestra que **no existen diferencias estadísticamente significativas** entre modelos (p -valor = 0.9289).

5.4.2. Comparación entre modelos

En este apartado se comparan los modelos de clasificación SVM, Decision Tree, LDA y QDA en términos de precisión y errores cometidos.




Figura 5: Matrices de confusión obtenidas con LDA, QDA, Decision Tree y SVM utilizando LOOCV.

Los cuatro modelos clasifican correctamente todas las muestras de la clase Iris-setosa (100%). Para Iris-versicolor, el modelo SVM combinación 9 comete 4 errores (8%), clasificando algunas muestras como Iris-virginica, mientras que LDA, QDA y el Árbol de Decisión muestran un desempeño ligeramente superior en esta clase. En la clase Iris-virginica, SVM presenta 4 errores (8%) al clasificarlas como Iris-versicolor, mientras que LDA y QDA mantienen precisiones cercanas al 98%, y el Árbol de Decisión muestra una precisión del 94%. En general, los modelos logran una clasificación robusta para Iris-setosa, mientras que las confusiones principales se concentran entre Iris-versicolor e Iris-virginica.

En general, LDA muestra el rendimiento promedio más alto en este conjunto de datos, seguido por QDA, Decision Tree y SVM. Aunque las diferencias en la *accuracy* media son aparentes, es necesario evaluar si estas diferencias son estadísticamente significativas.

Cuadro 3: Comparación de la *accuracy* media y desviación estándar entre modelos

Modelo	Accuracy media	Desviación estándar
LDA	0.980	$3,22 \times 10^{-2}$
QDA	0.973	$4,66 \times 10^{-2}$
Decision Tree	0.960	$5,62 \times 10^{-2}$
SVM	0.953	$6,32 \times 10^{-2}$

En la Tabla 3 se observa que LDA alcanza la mayor precisión media (0.98000), seguido de QDA y Decision Tree, mientras que SVM muestra la precisión promedio más baja y la mayor variabilidad.

Para evaluar si estas diferencias son estadísticamente significativas, se aplicó el test de Kruskal-Wallis sobre las distribuciones de *accuracy* de los modelos. Se obtuvo un p -valor de 0.7225, lo que indica que no existen diferencias significativas entre los modelos ($p > 0,05$).

Aunque LDA mostró un rendimiento medio superior y SVM presentó una mayor dispersión en los resultados, estas diferencias no fueron estadísticamente relevantes.

5.4.3. Selección del mejor modelo para la resolución del problema

El test de Kruskal-Wallis mostró que no existen diferencias estadísticamente significativas en la *accuracy* entre LDA, QDA, Decision Tree y SVM, aunque SVM presentó la media más baja y la mayor variabilidad, por lo que se descarta como la mejor opción. Entre los modelos restantes, LDA ofrece la mayor precisión media y la menor desviación estándar, combinando además baja complejidad computacional y estabilidad en conjuntos de datos pequeños. Por tanto, se concluye que LDA es la mejor opción para este análisis, al lograr un equilibrio óptimo entre eficiencia, robustez y simplicidad.

6 QSAR biodegradation dataset

6.1. Fase 0: Exploración inicial de los datos

Se han generado diagramas de caja para visualizar la distribución de las variables cuantitativas y diagramas de barras para las variables cualitativas.

6.1.1. Distribución de las variables

Las variables cuantitativas del dataset QSAR han sido visualizadas mediante diagramas de caja en la Figura 6. Estos diagramas permiten identificar la distribución de los datos, así como la presencia de valores atípicos.

La mayoría de las variables presentan una cantidad significativa de valores atípicos (puntos rojos fuera de los bigotes del diagrama). Esto indica que los datos contienen valores extremos que podrían requerir tratamiento en el preprocesamiento. Por ejemplo: SpMax_L, SdssC, HyWi_m, LOC, SpMAX_B(m) y SM6_m.

Algunas variables también muestran una asimetría evidente, lo que sugiere que su distribución no es normal. Ejemplos claros de esto son: sdO, Ti2_L y C %, las cuales presentan una distribución altamente sesgada con valores extremos en un solo lado.




Figura 6: Diagramas de caja de las variables cuantitativas del dataset QSAR.

La Figura 7 presenta diagramas de barras para las variables cualitativas del dataset QSAR. Este tipo de visualización permite observar la frecuencia de las categorías en cada variable.

La mayoría de las variables presentan distribuciones altamente sesgadas, con valores concentrados en un número reducido de categorías. Variables como nHM, nCp, nCRX3, nN y nX tienen gran cantidad de muestras pertenecientes a la categoría más baja.

Otras variables como F04[C-N], F03[C-O] y C-026, tienen valores más dispersos, aunque siguen mostrando una concentración fuerte en los valores más bajos.

Para la variable a predecir, se observa que hay un posible desbalance en la distribución, con más ejemplos en una categoría NRB que en RB, lo que se puede ver reflejado en el desempeño de modelos de clasificación.




Figura 7: Histogramas de las variables cualitativas del dataset QSAR.

6.1.2. Matriz de correlación




Figura 8: Matriz de correlaciones QSAR.

Como vemos en la Figura 8, la mayoría de las celdas en la matriz presentan valores cercanos a 0 (colores verdes y amarillos), lo que indica que muchas variables no están fuertemente relacionadas entre sí.

Se observa que las correlaciones positivas más altas (en tonos rojo oscuro) se presentan entre las variables SpMax_A con SpMax_B(m) y Psi_i_A. Además, F04[C-N] y F02[C-N] muestran también una relación fuerte, lo que sugiere que ambas variables podrían estar capturando información similar sobre la estructura química de los compuestos.

En cuanto a las correlaciones negativas (en azul), se identifican relaciones destacadas entre nN-N y nO, así como entre nCIR y nArNO2. Estos valores negativos sugieren que cuando una de estas variables aumenta, la otra tiende a disminuir.

6.2. Fase 1: Preprocesado de datos

6.2.1. Datos atípicos

Se identificaron valores atípicos en múltiples variables utilizando el método de detección basado en cuartiles. Las variables con valores extremos incluyen:

SpMax_L	J_Dz(e)	HyWi_B(m)
LOC	SM6_L	SpPosA_B(p)
Psi_i1d	TF2_L	SpMax_B(m)
Psi_iA	SM6_B(m)	

Para minimizar el impacto de estos valores extremos sin eliminar información relevante, los valores atípicos fueron reemplazados por la mediana de la variable correspondiente.

6.2.2. Normalización

Dado que las variables predictoras presentan escalas distintas, se realizó una normalización de las variables cuantitativas utilizando el método Z-score.

Esta normalización se llevó a cabo dentro de cada iteración de validación cruzada para evitar la fuga de datos (*data leakage*).

6.3. Fase 2: Aprendizaje

En esta fase, se configuraron y entrenaron los modelos de Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), distintos árboles de decisión y máquinas de vectores soporte (SVM) en el dataset QSAR Biodegradation, utilizando validación cruzada con 10 folds para evaluar su rendimiento.

6.3.1. Configuración del método de aprendizaje

Para la clasificación de compuestos biodegradables (RB) y no biodegradables (NRB) en el dataset QSAR, se aplicaron los siguientes modelos:

- **Discriminante Lineal de Fisher (LDA):** Asume covarianzas iguales entre clases y genera fronteras lineales. Se utilizó en su configuración estándar, sin ajuste adicional de hiperparámetros.
- **Discriminante Pseudo-Cuadrático (QDA):** Variante regularizada del QDA estándar, adecuada para manejar la varianza cero detectada en algunas variables de la clase RB.
- **Árbol de Decisión:** Se entrenaron 27 modelos variando tres hiperparámetros clave: profundidad máxima ($MaxDepth = 10, 30, 50$), tamaño mínimo de las hojas ($MinLeafSize = 1, 5, 10$) y tamaño mínimo del nodo padre ($MinParentSize = 2, 10, 20$).
- **Máquinas de Vectores Soporte (SVM):** Se evaluaron nueve configuraciones, combinando tres kernels (*lineal*, *gaussiano*, *polinómico*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. Se realizaron tres repeticiones independientes para robustecer las estimaciones.

6.3.2. Selección del método de estimación del error real

Se utilizó validación cruzada estratificada con $K = 10$ folds, garantizando la preservación de la proporción de clases en cada partición. En el caso de las SVM, este procedimiento se repitió tres veces, permitiendo evaluar la estabilidad de las métricas frente a variaciones de la partición.

6.3.3. Elección de las métricas de evaluación

Se calcularon las métricas de *Accuracy*, *Recall*, *Specificity*, *Precision* y *F1-score* para cada fold. Dado el desbalance de clases presente en el dataset, se consideró el *F1-score* como la métrica principal para la selección del mejor modelo, al balancear precisión y exhaustividad en la identificación de la clase minoritaria.

6.3.4. Entrenamiento y obtención de resultados

Los modelos fueron entrenados y evaluados utilizando validación cruzada de la siguiente manera:

1. Se dividió el dataset en 10 subconjuntos de igual tamaño.
2. Se entrenó el modelo con 9 folds y se probó en el fold restante.
3. Se registraron las predicciones y se construyó la matriz de confusión.
4. Se repitió el proceso hasta que cada fold fuera utilizado como conjunto de prueba.
5. Se calcularon las métricas de evaluación promediando los resultados de los 10 folds.

Los resultados obtenidos se presentarán en la siguiente sección, donde se compararán los modelos en términos de precisión y otras métricas de rendimiento.

6.4. Fase 3: Análisis de resultados y comparación de modelos

En esta sección se presentan los resultados obtenidos para los modelos Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), Árboles de Decisión y Máquinas de Vectores de Soporte (SVM) en el dataset QSAR biodegradation. Se analizan las métricas de evaluación obtenidas en cada caso, se comparan los modelos mediante pruebas estadísticas no paramétricas y se selecciona el modelo más adecuado para resolver la tarea de clasificación.

6.4.1. Resultados de clasificación

En la Tabla 4 se presentan los resultados promedio y desviación estándar para las configuraciones de SVM evaluadas en el dataset QSAR. Los modelos con kernel lineal mostraron las mejores métricas globales, mientras que los modelos gaussianos presentaron baja sensibilidad, a pesar de su alta especificidad. Los modelos polinómicos ofrecieron un rendimiento intermedio, destacando especialmente en precisión.

Cuadro 4: Resultados de las configuraciones de SVM en el dataset QSAR

Parámetros			Métricas				
Modelo	Kernel	C	Accuracy	Recall	Precision	Specificity	F1-score
SVM 1	lineal	1	$0,868 \pm 3,04 \times 10^{-2}$	$0,783 \pm 6,20 \times 10^{-2}$	$0,822 \pm 5,69 \times 10^{-2}$	$0,912 \pm 3,11 \times 10^{-2}$	$0,800 \pm 4,77 \times 10^{-2}$
SVM 2	lineal	3	$0,870 \pm 1,95 \times 10^{-2}$	$0,780 \pm 5,30 \times 10^{-2}$	$0,826 \pm 1,57 \times 10^{-1}$	$0,915 \pm 1,47 \times 10^{-2}$	$0,801 \pm 8,14 \times 10^{-2}$
SVM 3	lineal	5	$0,870 \pm 6,44 \times 10^{-2}$	$0,781 \pm 1,57 \times 10^{-1}$	$0,826 \pm 1,01 \times 10^{-1}$	$0,915 \pm 4,17 \times 10^{-2}$	$0,801 \pm 1,27 \times 10^{-1}$
SVM 4	gaussiana	1	$0,697 \pm 3,89 \times 10^{-2}$	$0,111 \pm 7,32 \times 10^{-2}$	$0,915 \pm 6,82 \times 10^{-2}$	$0,995 \pm 3,93 \times 10^{-2}$	$0,196 \pm 5,94 \times 10^{-2}$
SVM 5	gaussiana	3	$0,700 \pm 2,30 \times 10^{-2}$	$0,140 \pm 6,60 \times 10^{-2}$	$0,845 \pm 1,37 \times 10^{-1}$	$0,985 \pm 1,25 \times 10^{-2}$	$0,235 \pm 9,59 \times 10^{-2}$
SVM 6	gaussiana	5	$0,705 \pm 9,01 \times 10^{-2}$	$0,158 \pm 2,31 \times 10^{-1}$	$0,831 \pm 1,45 \times 10^{-1}$	$0,984 \pm 9,79 \times 10^{-2}$	$0,262 \pm 1,87 \times 10^{-1}$
SVM 7	polinómica	1	$0,772 \pm 3,38 \times 10^{-2}$	$0,692 \pm 7,67 \times 10^{-2}$	$0,657 \pm 5,65 \times 10^{-2}$	$0,814 \pm 3,11 \times 10^{-2}$	$0,667 \pm 5,46 \times 10^{-2}$
SVM 8	polinómica	3	$0,766 \pm 1,68 \times 10^{-2}$	$0,655 \pm 4,95 \times 10^{-2}$	$0,633 \pm 1,22 \times 10^{-1}$	$0,822 \pm 1,32 \times 10^{-2}$	$0,640 \pm 7,41 \times 10^{-2}$
SVM 9	polinómica	5	$0,775 \pm 8,17 \times 10^{-2}$	$0,657 \pm 1,80 \times 10^{-1}$	$0,662 \pm 1,37 \times 10^{-1}$	$0,835 \pm 5,59 \times 10^{-2}$	$0,649 \pm 1,55 \times 10^{-1}$

Para evaluar si existían diferencias significativas entre las configuraciones de SVM en el dataset QSAR, se aplicó el test no paramétrico de Kruskal-Wallis sobre las métricas de *accuracy*, *recall*, *specificity*, *precision* y *F1-score*.

Los resultados mostraron diferencias estadísticamente significativas para **accuracy** (p-valor < 0,0001), **recall** (p-valor < 0,0001), **specificity** (p-valor < 0,0001), **precision** (p-valor < 0,0001) y **F1-score** (p-valor < 0,0001) en el análisis global entre las nueve configuraciones de SVM. Las comparaciones múltiples indicaron que los modelos con kernel lineal y polinómico no presentan diferencias significativas entre sí (p-valor > 0,05), mientras que las configuraciones gaussianas difieren significativamente del resto, mostrando alta *specificity* pero bajo *recall* y *F1-score*.




Figura 9: Comparaciones múltiples entre configuraciones de SVM para *F1-Score*.

Dado que no se observaron diferencias estadísticamente significativas entre los modelos lineales y polinómicos, se seleccionó el modelo lineal más simple ($C = 1$) como la mejor opción, priorizando la simplicidad y la estabilidad.

6.4.2. Comparación entre modelos

En esta sección se comparan los mejores modelos de LDA, QDA, Árbol de Decisión y SVM, analizando diferentes métricas de rendimiento.

Se encontraron diferencias significativas en **accuracy** ($p = 0.0139$), **recall** ($p = 0.0450$) y **F1-score** ($p = 0.0052$), mientras que no se hallaron diferencias significativas en **specificity** ($p = 0.4253$) ni **precision** ($p = 0.2269$).

El gráfico de la Figura 10 muestra las comparaciones múltiples para la métrica de *accuracy*, tras aplicar la corrección de Bonferroni luego de detectar diferencias globales significativas con la prueba de Kruskal-Wallis. En el eje y se representan los modelos comparados, y en el eje x, sus ranks promedio. Los intervalos de confianza reflejan la variabilidad interna de cada grupo. El análisis indicó que las diferencias significativas aparecen principalmente entre SVM y Árbol de Decisión, mientras que LDA y QDA muestran un comportamiento intermedio y no significativamente diferente.




Figura 10: Comparaciones múltiples para Accuracy entre LDA, QDA, Árbol de Decisión y SVM

La Figura 11 presenta las comparaciones para la métrica **F1-score**, métrica que es de gran importancia para comparar distintos modelos en *datasets* desbalanceados, como es el caso de QSAR. Aquí también se detectan diferencias significativas entre SVM y Árbol de Decisión, confirmando que SVM logra un mejor equilibrio entre precisión y exhaustividad. Sin embargo, las diferencias entre LDA, QDA y SVM no alcanzan significancia estadística, lo que sugiere un desempeño comparable en este indicador.




Figura 11: Comparaciones múltiples para F1-score entre LDA, QDA, Árbol de Decisión y SVM

Finalmente, en la Figura 12 se muestran las comparaciones múltiples para **recall**. Los resultados evidencian que, aunque el test de Kruskal-Wallis detectó diferencias significativas globalmente, estas diferencias sólo son estadísticamente relevantes entre SVM y Árbol de Decisión. Entre LDA, QDA y SVM, las diferencias no alcanzan significancia, reafirmando que su capacidad para identificar correctamente casos positivos es similar.




Figura 12: Comparaciones múltiples para Recall entre LDA, QDA, Árbol de Decisión y SVM

6.4.3. Selección del mejor modelo para la resolución del problema

El análisis estadístico mostró diferencias significativas en **F1-score** entre los modelos, destacando SVM, LDA y QDA frente al Árbol de Decisión, que presentó un rendimiento inferior. Aunque SVM obtuvo una accuracy promedio ligeramente superior, no se encontraron diferencias significativas respecto a LDA. Por su simplicidad y estabilidad, se selecciona **LDA** como el modelo final, ya que ofrece un buen equilibrio entre rendimiento y baja complejidad computacional.

7 Henon dataset

7.1. Fase 0: Exploración inicial de los datos

Para analizar la dinámica de la serie Henon, se seleccionaron 1.500 muestras consecutivas extraídas aleatoriamente de un total de 300.000. La serie fue visualizada representando sus últimas 50 observaciones, mostrando oscilaciones complejas características de sistemas caóticos.

NumMissing	Min	Median	Max	Mean	Std
0	-1.2817	0.4095	1.2729	0.2578	0.7207

Cuadro 5: Estadísticas descriptivas de las 1500 muestras de la serie Henon

7.1.1. Distribución de las variables

Se realizó un gráfico de líneas con puntos (ver Figura 13), que evidenció la variabilidad y los cambios abruptos de la serie, sugiriendo la necesidad de emplear métodos capaces de capturar no linealidades.




Figura 13: Últimos 50 valores de la serie Henon.

7.2. Fase 1: Preprocesado de datos

7.2.1. Generación de conjuntos de datos

Se generaron dos conjuntos de datos a partir de la serie Henon utilizando ventanas deslizantes de tamaño 5 y 10. Cada conjunto se dividió en entradas (INPUTS) y salidas (OUTPUTS) para las tareas de predicción.

Conjunto	Entradas (filas $\times$ columnas)	Salidas (filas $\times$ columnas)
Ventana 5	1495×5	1495×1
Ventana 10	1490×10	1490×1

Cuadro 6: Dimensiones de los conjuntos de datos generados con ventanas de tamaño 5 y 10.

7.3. Fase 2: Aprendizaje

7.3.1. Configuración del método de aprendizaje

Se entrenaron modelos SVM de regresión combinando tres funciones kernel (lineal, gaussiana y polinómica) con tres valores de parámetro de penalización $C = \{1, 3, 5\}$. Para cada combinación, se utilizaron ventanas de tamaño 5 y 10, generando un total de nueve modelos por conjunto.

7.3.2. Selección del método de estimación del error real

Se utilizó validación cruzada K-fold ($K = 10$) repetida tres veces. En cada repetición, los datos se dividieron aleatoriamente en 10 subconjuntos, entrenando el modelo con nueve de ellos y evaluando en el restante. Este procedimiento permitió estimar métricas de error promedio y su variabilidad.

7.3.3. Elección de las métricas de evaluación

El rendimiento de los modelos se evaluó utilizando las siguientes métricas de regresión:

- **MSE (Mean Squared Error):** Error cuadrático medio.
- **RMSE (Root Mean Squared Error):** Raíz del error cuadrático medio.
- **MAE (Mean Absolute Error):** Error absoluto medio.

Estas métricas permiten cuantificar la precisión de las predicciones en términos absolutos y relativos.

7.3.4. Entrenamiento y obtención de resultados

Los modelos se entrenaron y evaluaron siguiendo los pasos:

1. Dividir los datos en entrenamiento y prueba según el esquema K-fold.
2. Calcular parámetros de normalización Z-score en el conjunto de entrenamiento y aplicarlos al conjunto de prueba.
3. Entrenar el modelo SVM de regresión en el conjunto de entrenamiento.
4. Realizar predicciones en el conjunto de prueba.
5. Calcular métricas de error para cada fold y repetición.

Al finalizar, se calcularon medias y desviaciones estándar para MSE, RMSE y MAE, permitiendo comparaciones consistentes entre modelos.

7.4. Fase 3: Análisis de resultados y comparación de modelos

7.4.1. Resultados de regresión

La Tabla 7 resume el rendimiento de nueve configuraciones de SVM en el dataset Henon utilizando una ventana de tamaño $d = 5$, sin aplicar normalización a las entradas. Se reportan tres

métricas clave: MSE, RMSE y MAE, junto con sus desviaciones estándar. Los modelos lineales (SVM 1–3) presentan los peores resultados, con errores MSE cercanos a 0,47 y RMSE en torno a 0,68, reflejando limitaciones claras para capturar la complejidad del sistema. Las configuraciones con kernel gaussiano (SVM 4–6) obtienen mejoras notables, con valores promedio de MSE entre 0,0034 y 0,0033, y RMSE en torno a 0,058. Finalmente, los modelos polinómicos (SVM 7–9) alcanzan los mejores resultados globales, con MSE mínimos (0,0034) y valores de MAE consistentemente inferiores a 0,052.

Cuadro 7: Resultados de las configuraciones de SVM en el dataset Henon ($d = 5$, sin normalización)

Parámetros			Métricas		
Modelo	Kernel	C	MSE	RMSE	MAE
SVM 1	lineal	1	$0,469 \pm 8,05 \times 10^{-2}$	$0,682 \pm 5,81 \times 10^{-2}$	$0,515 \pm 3,64 \times 10^{-2}$
SVM 2	lineal	3	$0,470 \pm 2,44 \times 10^{-4}$	$0,684 \pm 2,11 \times 10^{-3}$	$0,516 \pm 2,44 \times 10^{-3}$
SVM 3	lineal	5	$0,470 \pm 1,97 \times 10^{-4}$	$0,683 \pm 1,67 \times 10^{-3}$	$0,516 \pm 1,92 \times 10^{-3}$
SVM 4	gaussiana	1	$0,0034 \pm 8,47 \times 10^{-2}$	$0,058 \pm 6,05 \times 10^{-2}$	$0,052 \pm 3,59 \times 10^{-2}$
SVM 5	gaussiana	3	$0,0034 \pm 2,03 \times 10^{-4}$	$0,058 \pm 1,73 \times 10^{-3}$	$0,051 \pm 2,10 \times 10^{-3}$
SVM 6	gaussiana	5	$0,0034 \pm 1,66 \times 10^{-4}$	$0,058 \pm 1,42 \times 10^{-3}$	$0,051 \pm 1,74 \times 10^{-3}$
SVM 7	polinómica	1	$0,0034 \pm 6,72 \times 10^{-2}$	$0,058 \pm 4,95 \times 10^{-2}$	$0,052 \pm 2,99 \times 10^{-2}$
SVM 8	polinómica	3	$0,0034 \pm 2,10 \times 10^{-4}$	$0,058 \pm 1,81 \times 10^{-3}$	$0,052 \pm 2,14 \times 10^{-3}$
SVM 9	polinómica	5	$0,0034 \pm 2,09 \times 10^{-4}$	$0,059 \pm 1,78 \times 10^{-3}$	$0,053 \pm 2,22 \times 10^{-3}$

Se realizó un análisis ANOVA para comparar los modelos en términos de MSE, RMSE y MAE. En todos los casos, el valor- p fue menor que 0.0001, indicando diferencias estadísticamente significativas entre las configuraciones evaluadas.

Las Figuras 14, 15 y 16 muestran los resultados de las comparaciones múltiples para cada métrica. Se observa que los modelos 7, 8 y 9 (con kernel polinómico) no presentan diferencias significativas con respecto a los modelos 4, 5 y 6 (con kernel gaussiano), formando un grupo homogéneo con los errores más bajos, y destacando claramente sobre los modelos 1, 2 y 3 (con kernel lineal), que presentan un desempeño sustancialmente inferior.




Figura 14: Comparaciones múltiples para MSE en $d = 5$.




Figura 15: Comparaciones múltiples para RMSE en $d = 5$.




Figura 16: Comparaciones múltiples para MAE en $d = 5$.

A pesar de que los modelos polinómicos (SVM 7–9) obtienen los valores más bajos de error en promedio, se optó por seleccionar el modelo **SVM4** (kernel gaussiano, $C = 1$) como mejor opción para $d = 5$. Esta decisión se basa en su excelente equilibrio entre rendimiento, estabilidad y simplicidad, así como en su menor susceptibilidad al sobreajuste frente a las configuraciones polinómicas, lo que lo convierte en una opción más robusta para tareas de predicción en series caóticas como Henon.

En la Tabla 8 se muestran los resultados de las nueve configuraciones de SVM sobre el dataset Henon utilizando una ventana de tamaño $d = 10$, sin aplicar normalización a las entradas. Como en el caso anterior con $d = 5$, se reportan las métricas MSE, RMSE y MAE junto a sus desviaciones estándar.

Cuadro 8: Resultados de las configuraciones de SVM en el dataset Henon ($d = 10$)

Parámetros			Métricas		
Modelo	Kernel	C	MSE	RMSE	MAE
SVM 1	lineal	1	$0,417 \pm 5,08 \times 10^{-2}$	$0,644 \pm 3,89 \times 10^{-2}$	$0,502 \pm 2,75 \times 10^{-2}$
SVM 2	lineal	3	$0,413 \pm 2,64 \times 10^{-3}$	$0,642 \pm 1,29 \times 10^{-2}$	$0,499 \pm 5,33 \times 10^{-3}$
SVM 3	lineal	5	$0,415 \pm 3,09 \times 10^{-4}$	$0,643 \pm 2,65 \times 10^{-3}$	$0,500 \pm 2,90 \times 10^{-3}$
SVM 4	gaussiana	1	$0,010 \pm 5,70 \times 10^{-2}$	$0,099 \pm 4,38 \times 10^{-2}$	$0,076 \pm 3,69 \times 10^{-2}$
SVM 5	gaussiana	3	$0,010 \pm 2,29 \times 10^{-3}$	$0,100 \pm 1,12 \times 10^{-2}$	$0,076 \pm 4,10 \times 10^{-3}$
SVM 6	gaussiana	5	$0,010 \pm 3,37 \times 10^{-4}$	$0,099 \pm 2,83 \times 10^{-3}$	$0,075 \pm 3,25 \times 10^{-3}$
SVM 7	polinómica	1	$0,003 \pm 5,43 \times 10^{-2}$	$0,059 \pm 4,18 \times 10^{-2}$	$0,052 \pm 3,38 \times 10^{-2}$
SVM 8	polinómica	3	$0,003 \pm 3,30 \times 10^{-3}$	$0,059 \pm 1,49 \times 10^{-2}$	$0,052 \pm 5,43 \times 10^{-3}$
SVM 9	polinómica	5	$0,003 \pm 2,20 \times 10^{-4}$	$0,059 \pm 1,86 \times 10^{-3}$	$0,052 \pm 2,24 \times 10^{-3}$

Los modelos lineales (SVM 1–3) mantienen un rendimiento significativamente inferior, con MSE superiores a 0,41 y RMSE cercanos a 0,64, lo que reafirma su incapacidad para representar la dinámica no lineal de la serie Henon. Por otro lado, los modelos con kernel gaussiano (SVM 4–6) ofrecen mejoras sustanciales, con MSE reducidos a valores próximos a 0,006 y RMSE en torno a 0,078–0,080.

Sin embargo, las mejores métricas se observan en los modelos polinómicos (SVM 7–9), que obtienen MSE en torno a 0,0034, RMSE cercanos a 0,058 y MAE por debajo de 0,052. Entre ellos, destaca el modelo **SVM9** (kernel polinómico, $C = 5$), con el error más bajo de todos los modelos evaluados para esta configuración.

Se realizó un análisis ANOVA para comparar los modelos en términos de MSE, RMSE y MAE. En todos los casos, el p -valor fue $p < 0,0001$, indicando diferencias estadísticamente significativas entre las configuraciones de SVM. Las Figuras 17, 18 y 19 ilustran las comparaciones múltiples para cada métrica.

Se observa que los modelos 7, 8 y 9 (polinómicos) no se diferencian significativamente de los modelos 4, 5 y 6 (gaussianos), formando un grupo homogéneo con los errores más bajos. Todos ellos superan con claridad a las configuraciones con kernel lineal (SVM 1–3), que obtienen errores considerablemente mayores. Esta tendencia confirma el patrón observado en $d = 5$, reforzando la robustez de los modelos no lineales frente a los lineales para este tipo de series temporales.




Figura 17: Comparaciones múltiples para MSE en $d = 10$.




Figura 18: Comparaciones múltiples para RMSE en $d = 10$.




Figura 19: Comparaciones múltiples para MAE en $d = 10$.

Dado que el modelo **SVM4** (kernel gaussiano, $C = 1$) presentó un rendimiento competitivo en las tres métricas evaluadas y mostró un comportamiento robusto y estable en todas las particiones, se selecciona como el mejor modelo para la ventana de tamaño 10. Aunque el modelo SVM9 (kernel polinómico, $C = 5$) mostró un rendimiento ligeramente superior en términos de error medio, se optó por SVM4 debido a su menor complejidad y mayor estabilidad frente a variaciones en el parámetro C . Esta elección asegura un equilibrio adecuado entre rendimiento, simplicidad y generalización.

7.4.2. Comparación entre los dos mejores modelos SVM

En esta sección se comparan dos configuraciones del mismo modelo **SVM4** (kernel gaussiano, $C = 1$), evaluado con tamaños de ventana $d = 5$ y $d = 10$, respectivamente.

Los resultados muestran que el modelo con ventana más corta ($d = 5$) obtiene mejores métricas globales. En concreto, alcanza un MSE de $0,0034 \pm 8,47 \times 10^{-2}$, un RMSE de $0,058 \pm 6,05 \times 10^{-2}$, y un MAE de $0,052 \pm 3,59 \times 10^{-2}$. Por su parte, la configuración con $d = 10$ alcanza un MSE de $0,0064 \pm 5,67 \times 10^{-2}$, RMSE de $0,080 \pm 4,36 \times 10^{-2}$, y MAE de $0,067 \pm 3,66 \times 10^{-2}$.

Para evaluar la significancia de estas diferencias, se aplicó la prueba de Wilcoxon a las distribuciones de MSE, RMSE y MAE entre ambas configuraciones. En los tres casos se obtuvo un valor $p = 0,0020$, indicando que las diferencias son estadísticamente significativas a favor del modelo entrenado con $d = 5$.

Estos resultados indican que una ventana de tamaño $d = 5$ permite capturar mejor las relaciones locales relevantes para la predicción en la serie Henon, sin necesidad de aumentar la dimensionalidad del modelo, lo que también contribuye a una mayor estabilidad y menor riesgo de sobreajuste.

7.4.3. Selección del mejor modelo

El modelo seleccionado fue **SVM4** (kernel gaussiano, $C = 1$, ventana de tamaño 5), ya que presentó un equilibrio óptimo entre bajo error medio, estabilidad y simplicidad. Aunque otros modelos como SVM9 (polinómico, $C = 5$, $d = 10$) obtuvieron errores ligeramente inferiores, SVM4 demostró un rendimiento altamente competitivo, con menor complejidad y mayor robustez frente a variaciones en el parámetro C .

La comparación directa entre SVM4 evaluado con ventanas de tamaño $d = 5$ y $d = 10$ mediante la prueba de Wilcoxon mostró diferencias estadísticamente significativas ($p = 0,0020$) a favor de la configuración con $d = 5$, indicando que una ventana más corta captura mejor las relaciones temporales relevantes en esta serie caótica.

En la Figura 20 se muestra la comparación entre los valores reales y predichos para las últimas 50 muestras utilizando SVM4. El modelo logra un ajuste preciso incluso en zonas de alta variabilidad, lo que evidencia su capacidad de generalización.




Figura 20: Últimos 50 valores: Real vs. Predicho (SVM4, ventana 5)

Entre las métricas evaluadas, el **MAE** resulta especialmente útil para este tipo de problema, ya que proporciona una estimación directa del error medio sin amplificar excesivamente los errores extremos, como ocurre con el MSE y el RMSE. El bajo valor de MAE obtenido por SVM4 refuerza su elección como modelo más adecuado para predecir la dinámica de la serie Henon.

8 Discusión y Conclusiones

8.1. Discusión

Los resultados obtenidos en la clasificación del dataset Iris con los modelos de Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA) y Árbol de Decisión indican que todos los modelos logran una alta precisión en la identificación de las clases de flores, con diferencias mínimas en su desempeño. Específicamente, LDA presentó la menor cantidad de errores (3), seguido de QDA (4) y el Árbol de Decisión (6), lo que sugiere que LDA tiene una ligera ventaja en este conjunto de datos.

A nivel de métricas, LDA obtuvo la mayor precisión media (99%), seguido de QDA (98%) y el Árbol de Decisión (97%). Además, LDA también superó a los otros modelos en sensibilidad (98%) y F1-score (98%). Sin embargo, un análisis estadístico basado en el test de chi-cuadrado reveló que las diferencias entre los modelos no son estadísticamente significativas ($p = 0.5744$), lo que implica que ninguno de los modelos presenta una ventaja concluyente sobre los otros en términos de precisión.

En el caso del dataset QSAR Biodegradation, los resultados fueron similares en cuanto a la comparación entre LDA y QDA, aunque con diferencias más marcadas en la clasificación del Árbol de Decisión. QDA obtuvo un rendimiento ligeramente superior a LDA en algunas métricas (precisión de 84.74% vs. 84.17%, F1-score de 76.78% vs. 75.80%), pero estas diferencias fueron pequeñas. Al evaluar los distintos modelos de Árbol de Decisión, se encontró que los valores de profundidad intermedia y tamaño moderado de nodos mejoraban la estabilidad del modelo. A pesar de estos ajustes, los árboles de decisión mostraron una menor precisión global en comparación con LDA y QDA.

El test de Kruskal-Wallis indicó diferencias significativas en la precisión y especificidad entre los modelos ($p = 0.0131$ y $p = 0.0376$, respectivamente). Las comparaciones múltiples sugieren que el Árbol de Decisión tiene un rendimiento inferior al de QDA, pero no se encontraron diferencias significativas entre LDA y QDA en la mayoría de las métricas clave. Este resultado sugiere que ambos modelos son adecuados para la clasificación en este conjunto de datos, con una ligera ventaja para QDA en términos de sensibilidad y F1-score.

En el caso de los conjuntos generados a partir de la serie de Henon, se abordó un problema de regresión utilizando SVM con diferentes kernels (lineal, polinómico, gaussiano) y valores de C , aplicando validación cruzada de 10 folds repetida tres veces. Los resultados mostraron que los modelos con kernel gaussiano y polinómico obtuvieron los menores errores (MSE, RMSE, MAE), destacando frente a los modelos lineales. Específicamente, el modelo SVM4 (gaussiano, $C = 1$) fue evaluado en ambas configuraciones de ventana (tamaños 5 y 10), y se seleccionó como mejor modelo final la configuración con ventana de tamaño 5, debido a su menor error medio y mayor estabilidad.

El análisis ANOVA reveló diferencias estadísticamente significativas entre las configuraciones de SVM para todas las métricas evaluadas ($p < 0,0001$), y las comparaciones post hoc mostraron que los modelos con kernel gaussiano y polinómico forman un grupo homogéneo con errores significativamente más bajos que los modelos lineales. Posteriormente, el test de Wilcoxon permitió comparar los dos mejores modelos (ambos SVM4) con distintas ventanas, mostrando diferencias significativas en todas las métricas ($p = 0,0020$), favoreciendo al modelo con ventana de tamaño 5.

Estas observaciones reflejan que, en problemas de regresión, además de la selección del kernel, el tamaño de ventana de entrada tiene un papel crucial en el desempeño final del modelo. Asimismo, entre las métricas consideradas, el MAE resulta especialmente útil porque ofrece una medida interpretable del error medio absoluto, evitando el sesgo hacia errores grandes que presentan

MSE y RMSE. Finalmente, la gráfica de las últimas 50 predicciones frente a los valores reales muestra la alta capacidad predictiva del modelo seleccionado, confirmando su idoneidad para este tipo de datos.

8.2. Conclusiones

A partir del análisis realizado, se pueden extraer las siguientes conclusiones:

- **LDA como mejor modelo en el dataset Iris:** Aunque no se encontraron diferencias estadísticamente significativas entre los modelos, LDA presentó la menor cantidad de errores y la mayor precisión media, lo que lo convierte en la mejor opción para este conjunto de datos debido a su equilibrio entre simplicidad y rendimiento.
- **QDA y LDA con desempeños similares en el dataset QSAR:** Ambos modelos presentaron desempeños muy cercanos, con QDA obteniendo una ligera ventaja en algunas métricas, pero sin diferencias concluyentes en el test de Kruskal-Wallis. Por lo tanto, cualquiera de los dos modelos podría ser adecuado para este problema de clasificación.
- **El Árbol de Decisión es menos eficiente:** En ambos conjuntos de datos, el Árbol de Decisión presentó un mayor número de errores y una menor precisión global en comparación con LDA y QDA. Aunque ciertos hiperparámetros mejoraron su desempeño, sigue siendo menos competitivo que los modelos discriminantes.
- **Elección del mejor modelo para clasificación:** Para el dataset Iris, se recomienda LDA debido a su menor tasa de error y simplicidad computacional. Para el dataset QSAR, aunque QDA mostró una ligera ventaja, LDA sigue siendo una excelente opción por su estabilidad y menor complejidad. Dado que el Árbol de Decisión fue el modelo con peor desempeño en ambos casos, se descarta como la mejor alternativa para estos problemas de clasificación.
- **Modelos SVM para regresión:** En los conjuntos generados a partir de la serie de Henon, los modelos SVM con kernel gaussiano y polinómico mostraron un desempeño superior frente a los modelos lineales, destacando el modelo SVM4 (gaussiano, $C = 1$) con ventana de tamaño 5 como el mejor en términos de error medio y desviación estándar.
- **Importancia de la selección de la ventana y la métrica:** El tamaño de ventana de entrada resultó ser un factor crucial para el rendimiento, siendo la ventana de tamaño 5 superior a la de tamaño 10. Además, entre las métricas evaluadas, el MAE se identificó como la más adecuada al ofrecer una medida interpretable del error medio absoluto, menos sensible a valores extremos en comparación con MSE y RMSE.



UNIVERSIDADE DA CORUÑA

Aprendizaje basado en Redes Neuronales

Inteligencia Computacional para Bioinformática

Práctica 4



Autores:

Antía Dorado Valín
Oussama El Khatib
Pablo Torreira Pardo

A Coruña, 27 de mayo 2025

Índice

Índice de figuras	III
Índice de tablas	III
1 Introducción	1
2 Objetivos	1
3 Material y Métodos	3
3.1 Material	3
3.1.1 Datos	3
3.1.2 Software y bibliotecas	5
3.2 Métodos	5
3.2.1 Modelado y validación	5
4 Metodología	9
4.1 Análisis exploratorio	9
4.2 Preparación de los datos	9
4.3 Selección y validación del modelo	10
4.4 Selección del mejor modelo de clasificación	10
4.5 Entrenamiento final	10
5 Iris dataset	11
5.1 Fase 0: Exploración inicial de los datos	11
5.1.1 Distribución de las variables	11
5.1.2 Matriz de correlación	11
5.2 Fase 1: Preprocesado de datos	12
5.2.1 Datos atípicos	12
5.2.2 Normalización	12
5.2.3 Codificación de etiquetas	12
5.3 Fase 2: Aprendizaje	13
5.3.1 Configuración del método de aprendizaje	13
5.3.2 Selección del método de estimación del error real	13
5.3.3 Elección de las métricas de evaluación	14
5.3.4 Entrenamiento y obtención de resultados	14
5.4 Fase 3: Análisis de resultados y comparación de modelos	14
5.4.1 Resultados de clasificación	14
5.4.2 Comparación entre modelos	15
5.4.3 Selección del mejor modelo para la resolución del problema	16
6 QSAR biodegradation dataset	16
6.1 Fase 0: Exploración inicial de los datos	16
6.1.1 Distribución de las variables	16
6.1.2 Matriz de correlación	18
6.2 Fase 1: Preprocesado de datos	18
6.2.1 Datos atípicos	18
6.2.2 Normalización	18
6.3 Fase 2: Aprendizaje	19
6.3.1 Configuración del método de aprendizaje	19
6.3.2 Selección del método de estimación del error real	19
6.3.3 Elección de las métricas de evaluación	19
6.3.4 Entrenamiento y obtención de resultados	19
6.4 Fase 3: Análisis de resultados y comparación de modelos	20
6.4.1 Resultados de clasificación	20
6.4.2 Comparación entre modelos	20
6.4.3 Selección del mejor modelo para la resolución del problema	22
7 Henon dataset	22
7.1 Fase 0: Exploración inicial de los datos	22
7.1.1 Distribución de las variables	22
7.2 Fase 1: Preprocesado de datos	22
7.2.1 Generación de conjuntos de datos	22
7.3 Fase 2: Aprendizaje	23
7.3.1 Configuración del método de aprendizaje	23
7.3.2 Selección del método de estimación del error real	23
7.3.3 Elección de las métricas de evaluación	23
7.3.4 Entrenamiento y obtención de resultados	23
7.4 Fase 3: Análisis de resultados y comparación de modelos	24
7.4.1 Resultados de regresión ($d = 5$)	24

7.4.2	Comparación entre configuraciones de Redes Neuronales ($d = 5$)	24
7.4.3	Resultados de regresión ($d = 10$)	25
7.4.4	Comparación entre configuraciones de Redes Neuronales ($d = 10$)	25
7.5	Comparación entre modelos con diferentes tamaño de ventana	26
7.5.1	Comparación entre los dos mejores modelos NN	26
7.5.2	Selección del mejor modelo	26
7.5.3	Comparación entre el mejor modelo SVM y el mejor modelo NN	27
8	Discusión y Conclusiones	28
8.1	Discusión	28
8.2	Conclusiones	29

Índice de figuras

1	Leave-One-Out Cross-Validation (LOOCV)	6
2	K-Fold Cross-Validation	7
3	Diagramas de caja de las variables cuantitativas del dataset Iris.	11
4	Matriz de correlación entre las variables del dataset Iris.	12
5	Matrices de confusión obtenidas con LDA, QDA, Decision Tree, SVM y NN utilizando LOOCV.	15
6	Diagramas de caja de las variables cuantitativas del dataset QSAR.	17
7	Histogramas de las variables cualitativas del dataset QSAR.	17
8	Matriz de correlaciones QSAR.	18
9	Comparaciones múltiples para Accuracy entre LDA, QDA, Árbol de Decisión, SVM y NN	21
10	Comparaciones múltiples para F1-score entre LDA, QDA, Árbol de Decisión, SVM y NN	21
11	Boxplot del $F1$ -score para los distintos modelos comparados	21
12	Últimos 50 valores de la serie Henon.	22
13	Comparaciones múltiples para RMSE entre configuraciones de NNs ($d = 5$).	24
14	Comparaciones múltiples para MAE entre configuraciones de NNs ($d = 5$).	24
15	Comparaciones múltiples para MSE en $d = 10$ entre configuraciones de NNs.	25
16	Comparaciones múltiples para RMSE en $d = 10$ entre configuraciones de NNs.	25
17	Comparaciones múltiples para MAE en $d = 10$ entre configuraciones de NNs.	25
18	Últimos 50 valores: Real vs. Predicho (NN4, ventana 5)	26

Índice de tablas

1	Estadísticas descriptivas de las variables del dataset Iris.	11
2	Resultados de las configuraciones de Redes Neuronales en el dataset Iris	15
3	Comparación de la <i>accuracy</i> media y desviación estándar entre modelos	16
4	Resultados de las configuraciones de Redes Neuronales en el dataset QSAR	20
5	Métricas (media y desviación estándar) para los modelos evaluados en QSAR	21
6	Estadísticas descriptivas de las 1500 muestras de la serie Henon	22
7	Dimensiones de los conjuntos de datos generados con ventanas de tamaño 5 y 10.	22
8	Resultados de las configuraciones de Redes Neuronales en el dataset Henon ($d = 5$)	24
9	Resultados de las configuraciones de Redes Neuronales en el dataset Henon ($d = 10$)	25
10	Comparación entre las dos mejores configuraciones de NN con diferentes tamaños de ventana	26
11	Comparación entre el mejor modelo SVM y NN ($d = 5$)	27

1 Introducción

El análisis de datos se ha consolidado como una herramienta esencial en la toma de decisiones basada en evidencia, especialmente en el ámbito de la clasificación y el reconocimiento de patrones. En este estudio, se emplean dos conjuntos de datos ampliamente utilizados en la literatura científica: el dataset Iris y el dataset QSAR biodegradation. Ambos permiten evaluar el rendimiento de distintos modelos de clasificación en contextos variados, desde problemas de biología hasta química ambiental.

El dataset Iris, introducido por Ronald Fisher en 1936, es un clásico en la evaluación de algoritmos de clasificación. Contiene 150 observaciones de tres especies de flores (Iris setosa, Iris versicolor e Iris virginica), descritas por cuatro características morfométricas: longitud y ancho de sépalos y pétalos. Su simplicidad y equilibrio lo convierten en un referente ideal para validar modelos estadísticos.

Por otro lado, el dataset QSAR biodegradation se centra en predecir la biodegradabilidad de compuestos químicos. Contiene 41 descriptores moleculares que representan propiedades físicas, químicas y estructurales de 1055 compuestos, junto con una variable categórica que indica si el compuesto es biodegradable (RB) o no biodegradable (NRB). Este conjunto de datos permite evaluar el rendimiento de los modelos de clasificación en un contexto químico, con desafíos adicionales debido a su complejidad y mayor número de variables.

En el contexto de este análisis, la clasificación se convierte en un elemento fundamental para evaluar la capacidad de los modelos de diferenciar entre clases de manera precisa y consistente. Esto implica no solo identificar las características más relevantes de cada conjunto de datos, sino también aplicar métodos de validación robustos que permitan obtener una estimación confiable del rendimiento del modelo. Asimismo, en la parte de clasificación se incorporan Redes Neuronales Artificiales (ANN / NN), permitiendo comparar su rendimiento frente a los modelos clásicos previamente evaluados.

Además, esta práctica incluye una segunda parte centrada en la regresión, utilizando conjuntos generados a partir de la serie de Henon. En este caso, se aplican técnicas basadas en aprendizaje por Redes Neuronales. Este bloque complementa el análisis de clasificación, permitiendo explorar el ajuste de modelos a problemas continuos y evaluando su rendimiento mediante medidas de error específicas para regresión, siempre bajo un diseño experimental riguroso.

2 Objetivos

El objetivo principal de esta práctica es comparar el rendimiento de diferentes modelos de clasificación (LDA, QDA, Árboles de Decisión, SVM y Redes Neuronales en múltiples configuraciones) sobre los conjuntos de datos *Iris* y *QSAR biodegradation*. Para ello:

- Se entrenan y evalúan distintos modelos de clasificación, incluyendo, Redes Neuronales (con distintos tamaños de capa oculta y algoritmos de entrenamiento), SVM, LDA, QDA y Árboles de Decisión.
- Se evalúan cinco métricas de rendimiento: *Accuracy*, *Recall*, *Precision*, *Specificity* y *F1-score*.

- Se aplican **métodos de validación cruzada** adecuados a la naturaleza de cada conjunto, repitiendo los experimentos tres veces para asegurar robustez.
- Se realizan **comparaciones estadísticas** (Kruskal-Wallis y correcciones de Bonferroni) para determinar la existencia de diferencias significativas entre modelos.
- Se selecciona el **modelo más adecuado** para cada problema de clasificación, considerando tanto el rendimiento como la simplicidad computacional.

Adicionalmente, en la segunda parte de la práctica se aborda un problema de regresión utilizando datos generados a partir de la serie de Henon, considerando dos conjuntos con tamaños de ventana distintos ($d=5$ y $d=10$). Para ello:

- Se entrenan varias configuraciones de **Redes Neuronales para regresión**, modificando los hiperparámetros (número de neuronas en la capa oculta y función de entrenamiento empleada) y utilizando **validación cruzada de 10 folds** con tres repeticiones.
- Se evalúa el rendimiento de los modelos mediante métricas específicas de regresión: MSE (Mean Squared Error), RMSE (Root Mean Squared Error) y MAE (Mean Absolute Error).
- Se realizan **análisis estadísticos para comparar los modelos** (ANOVA y comparaciones múltiples con corrección de Bonferroni), identificando diferencias significativas entre las configuraciones evaluadas.
- Se comparan los mejores modelos obtenidos con distinto tamaño de ventana mediante el test de **Wilcoxon** para contrastar la influencia del tamaño de ventana en la capacidad predictiva.
- Se selecciona el **modelo final en función del rendimiento** y la estabilidad, destacando la mejor configuración para la predicción de series temporales.

3 Material y Métodos

3.1. Material

3.1.1. Datos

Este estudio utiliza dos conjuntos de datos del UCI Machine Learning Repository: el dataset **Iris** y el dataset **QSAR biodegradation**. Ambos permiten evaluar el rendimiento de distintos modelos de clasificación en contextos de biología y química ambiental.

El dataset **Iris** contiene 150 observaciones de tres especies de flores (*Iris setosa*, *Iris versicolor* e *Iris virginica*), descritas por cuatro variables cuantitativas:

- **SepalLength**: Longitud del sépalo (cm).
- **SepalWidth**: Ancho del sépalo (cm).
- **PetalLength**: Longitud del pétalo (cm).
- **PetalWidth**: Ancho del pétalo (cm).

El dataset **QSAR biodegradation** contiene información sobre 1055 compuestos químicos, descritos mediante 41 descriptores moleculares y clasificados en función de su biodegradabilidad en el medio ambiente:

- **SpMax_L**: Valor propio principal de la matriz de Laplace.
- **J_Dz(e)**: Índice tipo Balaban de la matriz de Barysz ponderado por la electronegatividad de Sanderson.
- **nHM**: Número de átomos pesados.
- **F01[N-N]**: Frecuencia de N-N a una distancia topológica de 1.
- **F04[C-N]**: Frecuencia de C-N a una distancia topológica de 4.
- **NssssC**: Número de átomos de tipo ssssC.
- **nCb-**: Número de carbonos (sp²) bencénicos sustituidos.
- **C %**: Porcentaje de átomos de carbono.
- **nCp**: Número de carbonos primarios terminales (sp³).
- **nO**: Número de átomos de oxígeno.
- **F03[C-N]**: Frecuencia de C-N a una distancia topológica de 3.
- **SdssC**: Suma de los estados E de dssC.
- **HyWi_B(m)**: Índice tipo Hyper-Wiener (función logarítmica) de la matriz de Burden ponderado por la masa.
- **LOC**: Índice de centrado de ramificación.
- **SM6_L**: Momento espectral de orden 6 de la matriz de Laplace.
- **F03[C-O]**: Frecuencia de C-O a una distancia topológica de 3.

- **Me**: Media de la electronegatividad atómica de Sanderson (escalada en el átomo de carbono).
- **Mi**: Media del primer potencial de ionización (escalado en el átomo de carbono).
- **nN-N**: Número de hidrazinas de N.
- **nArNO2**: Número de grupos nitro (aromáticos).
- **nCRX3**: Número de CRX3.
- **SpPosA_B(p)**: Suma espectral positiva normalizada de la matriz de Burden ponderada por la polarizabilidad.
- **nCIR**: Número de circuitos.
- **B01[C-Br]**: Presencia/ausencia de C-Br a una distancia topológica de 1.
- **B03[C-Cl]**: Presencia/ausencia de C-Cl a una distancia topológica de 3.
- **N-073**: Ar₂NH / Ar₃N / Ar₂N-Al / R..N..R.
- **SpMax_A**: Valor propio principal de la matriz de adyacencia (Índice Lovasz-Pelikan).
- **Psi_i_1d**: Índice de pseudoconectividad de estado intrínseco - tipo 1d.
- **B04[C-Br]**: Presencia/ausencia de C-Br a una distancia topológica de 4.
- **SdO**: Suma de los estados E de dO.
- **TI2_L**: Segundo índice de Mohar de la matriz de Laplace.
- **nCrt**: Número de carbonos terciarios en anillos (sp³).
- **C-026**: R-CX-R.
- **F02[C-N]**: Frecuencia de C-N a una distancia topológica de 2.
- **nHDon**: Número de átomos donadores de enlaces de hidrógeno (N y O).
- **SpMax_B(m)**: Valor propio principal de la matriz de Burden ponderado por la masa.
- **Psi_i_A**: Índice de pseudoconectividad de estado intrínseco - tipo S promedio.
- **nN**: Número de átomos de nitrógeno.
- **SM6_B(m)**: Momento espectral de orden 6 de la matriz de Burden ponderado por la masa.
- **nArCOOR**: Número de ésteres (aromáticos).
- **nX**: Número de átomos de halógenos.
- **experimental class**: Clase experimental (biodegradable listo (RB) y no biodegradable listo (NRB)).

Los datos fueron preprocesados para eliminar valores atípicos y garantizar la consistencia de las variables antes de aplicar los modelos de clasificación.

Además, se utiliza la **serie de Henon**, que es una secuencia temporal generada mediante un sistema dinámico no lineal. De esta serie se extraen 1500 muestras consecutivas elegidas aleatoriamente, que se transforman en conjuntos de regresión utilizando ventanas deslizantes de dos tamaños distintos:

- **Conjunto 1:** ventana de tamaño 5, generando variables predictoras a partir de las cinco observaciones anteriores.
- **Conjunto 2:** ventana de tamaño 10, generando variables predictoras a partir de las diez observaciones anteriores.

El objetivo con los datos Henon es evaluar el rendimiento de los modelos de regresión NN al predecir la siguiente observación en la serie, comparando configuraciones de hiperparámetros, así como el impacto del tamaño de la ventana en la calidad de la predicción.

3.1.2. Software y bibliotecas

El análisis y la implementación de los modelos fueron realizados en el entorno **MATLAB**, utilizando herramientas específicas para el modelado y la evaluación de los clasificadores:

- **fitcdiscr:** para entrenar modelos de clasificación basados en discriminante lineal de Fisher (LDA) y discriminante cuadrático (QDA).
- **fitctree:** para el entrenamiento de árboles de decisión, explorando distintas configuraciones de profundidad y tamaño de nodo.
- **fitsvm** y **templateSVM:** para entrenar máquinas de vectores soporte (SVM), combinando diferentes funciones kernel (*lineal*, *polinómica* y *gaussiana*) y valores del parámetro de penalización C .
- **fitrsvm:** para entrenar modelos de regresión SVM sobre los conjuntos generados a partir de la serie de Henon, evaluando múltiples configuraciones de kernel y valores de C .
- **patternnet:** para entrenar redes neuronales, explorando diferentes tamaños de la capa oculta y algoritmos de entrenamiento (*trainscg* y *trainlm*).
- **cvpartition:** para la partición de los datos mediante validación cruzada, tanto en modalidad *Leave-One-Out* (LOOCV) como en *K-fold estratificado*.
- **confusionmat** y **confusionchart:** para obtener y visualizar las matrices de confusión en cada iteración de validación.
- **boxplot**, **imagesc**, **histogram**, **scatter:** para el análisis exploratorio y representación gráfica de los datos.
- **kruskalwallis**, **multcompare**, **anova1**, **signrank:** para la realización de comparaciones estadísticas no paramétricas y análisis post hoc con corrección de Bonferroni o Wilcoxon.

3.2. Métodos

3.2.1. Modelado y validación

Se aplicaron cuatro modelos de **clasificación**:

- **Discriminante Lineal de Fisher (LDA):** Modelo que asume distribuciones gaussianas con la misma matriz de covarianza para todas las clases y busca maximizar la separación entre ellas mediante una frontera lineal. En este caso, se utilizó su configuración estándar, sin ajuste adicional de hiperparámetros.

- **Discriminante Cuadrático (QDA):** Similar a LDA, pero permite que cada clase tenga su propia matriz de covarianza, generando fronteras de decisión más flexibles. Se probó también en su variante pseudo-cuadrática, que introduce regularización para estabilizar la estimación de covarianzas en conjuntos de datos pequeños.
- **Árbol de Decisión:** Modelo jerárquico que divide los datos en subconjuntos según reglas de decisión en cada nodo. Se exploraron distintas combinaciones de parámetros clave, como la profundidad máxima (*MaxDepth*), el tamaño mínimo de las hojas (*MinLeafSize*) y el tamaño mínimo del nodo padre (*MinParentSize*), buscando el mejor equilibrio entre precisión y simplicidad.
- **Máquinas de Vectores Soporte (SVM):** Se evaluaron nueve configuraciones, combinando tres funciones *kernel* (*lineal*, *polinómica*, *gaussiana*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. En el caso del dataset Iris, se utilizó codificación *one-vs-one* para abordar la clasificación multiclase.
- **Redes Neuronales (NN):** Se implementaron redes neuronales multicapa (*multilayer perceptron*) configuradas con diferentes números de neuronas ocultas (5, 10, 15) y dos algoritmos de entrenamiento (*trainscg* y *trainlm*). Se aplicó codificación *one-hot* a las etiquetas de clase para facilitar el aprendizaje, y se utilizó validación cruzada estratificada para evaluar su rendimiento.
 - *trainscg* (Scaled Conjugate Gradient): Algoritmo de primer orden eficiente en problemas de clasificación con muchos patrones, ya que reduce el coste computacional al evitar el cálculo explícito del Hessiano.
 - *trainlm* (Levenberg-Marquardt): Algoritmo de segundo orden, más rápido en convergencia para problemas de tamaño moderado, ideal cuando se dispone de un número limitado de muestras y se busca precisión en el ajuste.

En la parte de **regresión**, se aplicaron modelos NN de regresión sobre los conjuntos generados a partir de la serie de Henon. Se utilizaron distintas configuraciones de hiperparámetros, aplicando validación cruzada de 10 folds repetida tres veces.

Para evaluar el rendimiento de los modelos, se utilizaron dos estrategias de validación cruzada:

- **Leave-One-Out Cross-Validation (LOOCV)** en el dataset Iris, dejando una observación para prueba en cada iteración. Esto se ha decidido teniendo en cuenta el tamaño muestral reducido (150 muestras). Este procedimiento se repitió tres veces, barajando los resultados tras cada iteración.




Figura 1: Leave-One-Out Cross-Validation (LOOCV)

El método se basa en realizar tantos pares de conjuntos train-test como muestras tengamos. En cada iteración se 'deja fuera' una de las muestras (que será utilizada para realizar la prueba) y se entrena con el resto de muestras. Repitiendo este procedimiento hasta que cada muestra ha sido utilizada como prueba una vez.

- **Validación K-Fold** ($K = 10$) en los datasets QSAR biodegradation y Henon, dividiendo el conjunto en 10 particiones y utilizando 9 para entrenamiento en cada iteración. Se decidió utilizar este método teniendo en cuenta que estos datasets presentan un mayor número de muestras (1055 y 1500 muestras respectivamente). Cada evaluación se repitió tres veces para garantizar la estabilidad de los resultados.



Figura 2: K-Fold Cross-Validation

Es una técnica de validación cruzada en la que el dataset se divide en K subconjuntos (o folds) de tamaño similar. En cada iteración, uno de estos folds se usa como conjunto de prueba, mientras que los $K-1$ restantes se utilizan para entrenar el modelo. Este proceso se repite K veces, asegurando que cada muestra se utilice como prueba una vez.

Para llevar a cabo las comparaciones entre modelos se utilizaron las siguientes pruebas estadísticas:

- **Kruskal-Wallis:** es una prueba no paramétrica que compara tres o más grupos independientes para determinar si provienen de la misma distribución. Es una extensión del test de Mann-Whitney y se usa cuando los datos no siguen una distribución normal. Su hipótesis nula establece que las medianas de los grupos son iguales.
- **Bonferroni:** es un método para ajustar el nivel de significancia en pruebas múltiples, reduciendo el riesgo de error tipo I (falsos positivos). Se calcula dividiendo el nivel de significancia entre el número de comparaciones realizadas. Se usa en comparaciones post hoc tras un ANOVA o Kruskal-Wallis.
- **ANOVA de un factor:** Prueba paramétrica que evalúa si existen diferencias significativas entre las medias de tres o más grupos independientes. Su hipótesis nula plantea que todas las medias poblacionales son iguales. Se emplea para analizar las métricas de error en los modelos de regresión.
- **Test de Wilcoxon para muestras apareadas (signrank):** Prueba no paramétrica utilizada para comparar dos muestras relacionadas, evaluando si sus medianas difieren significativamente. Se aplicó para comparar los modelos seleccionados entrenados con distintos tamaños de ventana en la serie de Henon.

La evaluación de los modelos se realizó mediante las siguientes métricas :

- **Precisión (Accuracy)**: Proporción de clasificaciones correctas sobre el total de observaciones.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Sensibilidad (Recall)**: Capacidad del modelo para identificar correctamente los casos positivos.

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **Especificidad (Specificity)**: Capacidad del modelo para identificar correctamente los casos negativos.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

- **Precisión Positiva (Precision)**: Proporción de predicciones positivas correctas.

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **F1-score**: Media armónica entre precisión y sensibilidad.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Error cuadrático medio (MSE)**: Promedio de los cuadrados de las diferencias entre los valores predichos y los valores reales.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Raíz del error cuadrático medio (RMSE)**: Raíz cuadrada del MSE, proporciona una interpretación en las mismas unidades que la variable objetivo.

$$RMSE = \sqrt{MSE}$$

- **Error absoluto medio (MAE)**: Promedio de las diferencias absolutas entre los valores predichos y los reales.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4 Metodología

Este estudio empleó un enfoque sistemático para resolver los problemas de clasificación en los datasets *Iris* y *QSAR biodegradation*, y de regresión en los conjuntos generados a partir de la serie de Henon. Se inició con la limpieza y preprocesamiento de los datos, seguido de un análisis exploratorio, la implementación de los modelos y la validación de los resultados.

4.1. Análisis exploratorio

Para comprender la estructura y relaciones de los datos, se realizó un análisis exploratorio mediante:

- Histogramas para visualizar la distribución de las variables.
- Diagramas de caja para detectar valores atípicos.
- Matriz de correlación para evaluar relaciones lineales entre variables.

La matriz de correlación se calculó utilizando el coeficiente de Pearson:

$$C_{ij} = \frac{\text{Cov}(X_i, X_j)}{\sigma_{X_i} \sigma_{X_j}},$$

donde:

- X_i, X_j son variables cuantitativas.
- $\text{Cov}(X_i, X_j)$ representa la covarianza entre X_i y X_j .
- $\sigma_{X_i}, \sigma_{X_j}$ son las desviaciones estándar.

Este análisis permitió detectar patrones en los datos y verificar la independencia de las variables predictoras.

4.2. Preparación de los datos

El proceso comenzó con la limpieza y transformación del conjunto de datos. Las variables fueron revisadas para asegurar su formato correcto según su naturaleza (numéricas o categóricas). Se eliminaron valores atípicos que podrían afectar el rendimiento de los modelos y se normalizaron las variables cuantitativas por el método Z-Score para evitar que diferencias en escala influyeran en la clasificación.

La normalización se realizó dentro de cada iteración de validación cruzada, asegurando que los datos de prueba no influyeran en el cálculo de los parámetros de normalización:

$$X_{\text{norm}} = \frac{X - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

donde μ_{train} y σ_{train} corresponden a la media y desviación estándar del conjunto de entrenamiento. Cabe destacar que, en el caso de la Red Neuronal, aunque lo correcto sería calcular los parámetros de normalización exclusivamente sobre el subconjunto de entrenamiento y aplicarlos luego al conjunto de validación, en esta práctica se ha mantenido la normalización sobre el conjunto completo de entrenamiento (incluyendo validación interna) por simplicidad metodológica.

4.3. Selección y validación del modelo

Clasificación: El proceso de selección del modelo incluyó la comparación de los resultados obtenidos con LDA, QDA, Árboles de Decisión, SVM y las diferentes configuraciones de redes neuronales. Para el dataset *Iris*, se aplicó validación cruzada Leave-One-Out (LOOCV), mientras que para el dataset *QSAR biodegradation* se utilizó validación cruzada K-fold, permitiendo una evaluación más adecuada dada la mayor cantidad de observaciones. En todos los casos, los modelos fueron comparados considerando métricas promedio obtenidas a partir de múltiples repeticiones, y se seleccionaron los mejores modelos no solo en función de su rendimiento, sino también de su simplicidad computacional y estabilidad.

En el caso de las redes neuronales, se utilizó como función de rendimiento la **cross-entropy** categórica, que resulta adecuada para problemas de clasificación multiclase y binaria, maximizando la probabilidad de predicción correcta sobre las categorías de salida. Aunque en el caso de uso del algoritmo de entrenamiento *trainlm* se reemplaza automáticamente por *squared-error*. Ambas funciones guían el ajuste de pesos durante el entrenamiento, permitiendo optimizar la asignación de probabilidades en las salidas codificadas mediante *one-hot encoding*.

Regresión: En los conjuntos generados a partir de la serie de Henon, se entrenaron modelos de regresión SVM utilizando combinaciones de kernels (lineal, polinómico, gaussiano) y valores de C. Se aplicó validación cruzada de 10 folds repetida tres veces. Las predicciones se evaluaron mediante métricas específicas para regresión: MSE, RMSE y MAE. Los resultados se analizaron mediante ANOVA de un factor y comparaciones post hoc con Bonferroni. Se utilizó un ANOVA de un factor porque, al disponer de un tamaño muestral suficientemente grande (gracias a la validación cruzada de 10 folds repetida tres veces), se puede asumir que la distribución de las métricas promedio (MSE, RMSE y MAE) tiende a la normalidad, según establece el teorema del límite central. Esto justifica el uso de ANOVA, que requiere como supuesto fundamental que las medias de los grupos a comparar sigan aproximadamente una distribución normal. Además, se aplicó el test de Wilcoxon para comparar el rendimiento de los modelos seleccionados con diferentes tamaños de ventana.

4.4. Selección del mejor modelo de clasificación

Para cada modelo entrenado, se calcularon las métricas de evaluación correspondientes. En clasificación: Accuracy, Recall, Precision, Specificity y F1-score; en regresión: MSE, RMSE y MAE. En ambos casos, se aplicaron pruebas estadísticas (Kruskal-Wallis y ANOVA, según correspondiera) para evaluar la existencia de diferencias estadísticamente significativas entre modelos. Cuando fue necesario, se realizaron comparaciones múltiples mediante el método de Bonferroni. En el análisis de regresión, el test de Wilcoxon permitió evaluar diferencias entre los modelos seleccionados en función del tamaño de ventana. La selección final consideró rendimiento, simplicidad computacional y estabilidad ante variaciones en los datos.

4.5. Entrenamiento final

Finalmente, tras evaluar el rendimiento de los modelos con validación cruzada, se entrenó un modelo final utilizando el conjunto completo de datos para cada dataset. Este modelo optimizado busca aprovechar toda la información disponible y maximizar su capacidad predictiva en aplicaciones futuras.

5 Iris dataset

5.1. Fase 0: Exploración inicial de los datos

Para comprender la distribución de las variables en el dataset Iris, se realizó un análisis exploratorio que incluyó estadísticas descriptivas, diagramas de caja (para observar la distribución de los valores en cada variable) y una matriz de correlación.

Variable	NumMissing	Min	Median	Max	Mean
SepalLength	0	4.3	5.8	7.9	5.8433
SepalWidth	0	2.0	3.0	4.4	3.0540
PetalLength	0	1.0	4.35	6.9	3.7587
PetalWidth	0	0.1	1.3	2.5	1.1987

Cuadro 1: Estadísticas descriptivas de las variables del dataset Iris.

5.1.1. Distribución de las variables

Los diagramas de caja permiten identificar valores atípicos y analizar la distribución de cada variable en el dataset. En la Figura 3, se presentan los boxplots para las cuatro variables principales.




Figura 3: Diagramas de caja de las variables cuantitativas del dataset Iris.

En estos gráficos se observa que *SepalWidth* presenta valores atípicos, identificados como puntos fuera de los límites de los bigotes, lo que sugiere una posible dispersión mayor en esta variable.

5.1.2. Matriz de correlación

Para evaluar las relaciones entre las variables cuantitativas, se calculó la matriz de correlación de Pearson, presentada en la Figura 4.




Figura 4: Matriz de correlación entre las variables del dataset Iris.

La matriz de correlación indica una relación fuerte y positiva entre *SepalLength* y *PetalLength* ($r = 0,8718$), así como entre *PetalLength* y *PetalWidth* ($r = 0,9628$). En contraste, *SepalWidth* muestra correlaciones negativas con otras variables, sugiriendo que podría aportar información diferenciada en la clasificación.

5.2. Fase 1: Preprocesado de datos

5.2.1. Datos atípicos

En este caso hemos decidido no transformar los datos considerados atípicos de la variable *SepalWidth*, ya que consideramos que estos valores entran dentro de lo posible y no creemos que se deba a un error de toma de datos, ni que vaya a afectar negativamente a la clasificación (más bien, podría ser un aspecto clave para la clasificación).

5.2.2. Normalización

Las variables predictoras (*SepalLength*, *SepalWidth*, *PetalLength* y *PetalWidth*) fueron normalizadas para evitar que las diferencias de escala afectaran la clasificación.

Se realizó dentro de cada iteración de validación cruzada, asegurando que los datos de prueba no influyeran en el cálculo de los parámetros de normalización, posteriormente se aplicó dicha normalización a los datos de prueba de cada iteración.

5.2.3. Codificación de etiquetas

Para permitir que las redes neuronales trabajaran correctamente con las clases del dataset Iris, se aplicó **One Hot Encoding** a la variable categórica *Species*. Este proceso consistió en transformar las etiquetas de clase (*Iris-setosa*, *Iris-versicolor*, *Iris-virginica*) en vectores binarios de tres posiciones, donde solo una posición está activada (valor 1) para la clase correspondiente y las demás permanecen en 0.

Este paso fue necesario exclusivamente para las redes neuronales, ya que los modelos clásicos (LDA, QDA, Árboles, SVM) trabajan directamente con etiquetas categóricas. Sin embargo, para asegurar la homogeneidad, se mantuvo un preprocesamiento cuidadoso en todos los modelos.

5.3. Fase 2: Aprendizaje

En esta fase, se configuraron y entrenaron los modelos de Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), Árboles de Decisión, Máquinas de Vectores Soporte (SVM) y Redes Neuronales (NN) en el dataset Iris, utilizando validación cruzada Leave-One-Out (LOOCV) para evaluar su rendimiento.

5.3.1. Configuración del método de aprendizaje

Para la clasificación de las especies de flores en el dataset Iris, se aplicaron los siguientes modelos:

- **LDA (Linear Discriminant Analysis)**: Se asume que las clases comparten la misma matriz de covarianza, generando fronteras de decisión lineales.
- **QDA (Quadratic Discriminant Analysis)**: Permite que cada clase tenga su propia matriz de covarianza, lo que posibilita fronteras de decisión curvas.
- **Árbol de Decisión**: modelo basado en una estructura jerárquica que divide los datos en subconjuntos según reglas de decisión en cada nodo. Se entrenaron diferentes modelos variando la profundidad del árbol, el tamaño mínimo de hoja (número mínimo de observaciones que debe contener un nodo hoja) y el tamaño mínimo del nodo padre (número mínimo de observaciones que debe tener un nodo antes de dividirse en nodos hijos).
- **SVM (Support Vector Machines)**: se evaluaron nueve configuraciones distintas, combinando tres funciones kernel (*lineal*, *gaussiana* y *polinómica*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. Para la clasificación multiclase se empleó la estrategia *one-vs-one*.
- **Redes Neuronales (Neural Networks)**: Se implementaron redes neuronales de una sola capa oculta (*single layer perceptron*) con distintas configuraciones, combinando tres tamaños de capa oculta (5, 10 y 15 neuronas) y dos algoritmos de entrenamiento (*trainscg* y *trainlm*). Las etiquetas fueron codificadas mediante *one-hot encoding* para permitir la salida multiclase, y se utilizó validación cruzada LOOCV para evaluar su rendimiento.

5.3.2. Selección del método de estimación del error real

Dado que el dataset Iris tiene un tamaño pequeño ($n = 150$), se utilizó **Leave-One-Out Cross-Validation (LOOCV)** como método de estimación del error real. Este enfoque entrena el modelo con $n - 1$ observaciones y prueba con la restante, repitiendo este proceso n veces.

Las ventajas de LOOCV incluyen:

- Maximiza el uso de los datos disponibles para entrenamiento.
- Proporciona una evaluación sin sesgo en datasets pequeños.
- Asegura que cada instancia sea utilizada como prueba en al menos una iteración.

En el caso de las NN, se repitió el procedimiento de LOOCV tres veces. Las predicciones obtenidas en cada repetición fueron barajadas y organizadas en 10 subconjuntos de igual tamaño, con el fin de calcular métricas por fold y permitir comparaciones estadísticas entre modelos.

5.3.3. Elección de las métricas de evaluación

Para comparar el rendimiento de LDA, QDA, Árboles de Decisión, SVM Y Redes Neuronales se utilizaron las métricas especificadas en el subapartado 3.2.1.

En cuanto a la importancia que presenta cada métrica para el problema concreto, se consideró que la **Accuracy** era la más adecuada para elegir el mejor modelo. Esta elección se debe a la necesidad de clasificar correctamente, sin preferencia por ninguna de las clases en particular.

5.3.4. Entrenamiento y obtención de resultados

Los modelos LDA, QDA, Árboles de Decisión, SVM y NN fueron entrenados y evaluados utilizando LOOCV de la siguiente manera:

1. Se separó una observación para prueba y se entrenó el modelo con las restantes $n - 1$.
2. Se registró la predicción para la muestra de prueba.
3. Se repitió el proceso para cada una de las n observaciones.
4. En el caso de las NNs, este procedimiento se repitió tres veces con diferentes semillas, y las predicciones resultantes se barajaron y dividieron en subconjuntos para el análisis estadístico.
5. Se construyeron las matrices de confusión y se calcularon las métricas de evaluación para cada modelo.

5.4. Fase 3: Análisis de resultados y comparación de modelos

En esta sección se presentan los resultados obtenidos para los modelos Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), Árboles de Decisión, Support Vector Machine (SVM) y Redes Neuronales (NN) en el dataset Iris. Se analizan las métricas de evaluación, se comparan los modelos mediante pruebas estadísticas y se selecciona el mejor modelo para la clasificación.

La *accuracy* se eligió como métrica principal de comparación porque resume de forma directa la proporción total de clasificaciones correctas sobre el conjunto de datos, ofreciendo una visión global del rendimiento de cada modelo. En este caso, dado que el conjunto Iris presenta clases balanceadas y bien definidas, la *accuracy* proporciona una medida adecuada y representativa del desempeño de los clasificadores, evitando la necesidad de métricas adicionales como el *recall* o la *precision*, que son especialmente relevantes en escenarios con clases desbalanceadas.

5.4.1. Resultados de clasificación

Además de los modelos LDA, QDA y Árboles de Decisión y SVM evaluados con su configuración más simple, se entrenaron seis configuraciones de redes neuronales (*Neural Networks*), combinando tres tamaños de capa oculta (5, 10, 15 neuronas) con dos algoritmos de entrenamiento (*trainscg* y *trainlm*).

Las métricas de rendimiento para los modelos NN fueron calculadas tras aplicar validación cruzada LOOCV con tres repeticiones. Los resultados obtenidos se agruparon en 10 subconjuntos para calcular medias y desviaciones estándar de forma coherente con los modelos anteriores. A continuación, se muestra el resumen de métricas globales para las redes neuronales:

Cuadro 2: Resultados de las configuraciones de Redes Neuronales en el dataset Iris

Parámetros			Métricas				
Modelo	Neurons	Algoritmo	Accuracy	Recall	Precision	Specificity	F1-score
NN 1	5	trainscg	$0.97481 \pm 2,85 \times 10^{-2}$	$0.96222 \pm 4,27 \times 10^{-2}$	$0.96704 \pm 3,92 \times 10^{-2}$	$0.98111 \pm 2,14 \times 10^{-2}$	$0.96193 \pm 4,30 \times 10^{-2}$
NN 2	10	trainscg	$0.97926 \pm 3,23 \times 10^{-2}$	$0.96889 \pm 4,85 \times 10^{-2}$	$0.97238 \pm 4,42 \times 10^{-2}$	$0.98444 \pm 2,42 \times 10^{-2}$	$0.96857 \pm 4,89 \times 10^{-2}$
NN 3	15	trainscg	$0.97778 \pm 2,85 \times 10^{-2}$	$0.96667 \pm 4,27 \times 10^{-2}$	$0.97201 \pm 3,63 \times 10^{-2}$	$0.98333 \pm 2,14 \times 10^{-2}$	$0.96623 \pm 4,34 \times 10^{-2}$
NN 4	5	trainlm	$0.97037 \pm 2,64 \times 10^{-2}$	$0.95556 \pm 3,96 \times 10^{-2}$	$0.96328 \pm 3,30 \times 10^{-2}$	$0.97778 \pm 1,98 \times 10^{-2}$	$0.95487 \pm 4,03 \times 10^{-2}$
NN 5	10	trainlm	$0.97037 \pm 3,26 \times 10^{-2}$	$0.95556 \pm 4,88 \times 10^{-2}$	$0.96381 \pm 3,92 \times 10^{-2}$	$0.97778 \pm 2,44 \times 10^{-2}$	$0.95473 \pm 5,01 \times 10^{-2}$
NN 6	15	trainlm	$0.96148 \pm 3,84 \times 10^{-2}$	$0.94222 \pm 5,75 \times 10^{-2}$	$0.94910 \pm 5,32 \times 10^{-2}$	$0.97111 \pm 2,88 \times 10^{-2}$	$0.94135 \pm 5,89 \times 10^{-2}$

Los resultados muestran que todas las configuraciones de redes neuronales presentan rendimientos elevados y consistentes, siendo especialmente destacables las redes entrenadas con el algoritmo *trainscg* y 10 neuronas en la capa oculta (NN 2), que obtienen las mejores puntuaciones en la mayoría de métricas. Las configuraciones con el algoritmo *trainlm* también ofrecen buenos resultados, aunque ligeramente inferiores a las obtenidas por *trainscg*.

Se ha comprobado si existen diferencias estadísticamente significativas entre las distintas configuraciones de redes neuronales en términos de *accuracy*, aplicando el test no paramétrico de Kruskal-Wallis sobre las puntuaciones obtenidas tras el reagrupamiento en folds. El resultado muestra que **no existen diferencias estadísticamente significativas** entre modelos (p-valor = 0.6067).

5.4.2. Comparación entre modelos

En este apartado se comparan los modelos de clasificación NN, SVM, Decision Tree, LDA y QDA en términos de precisión y errores cometidos.




Figura 5: Matrices de confusión obtenidas con LDA, QDA, Decision Tree, SVM y NN utilizando LOOCV.

Los cinco modelos clasifican correctamente todas las muestras de la clase Iris-setosa (100%). Para Iris-versicolor, el modelo de red neuronal (*NN combinación 1*) comete 3 errores (6%), clasificando varias muestras como Iris-virginica, mostrando un desempeño similar al resto de modelos para esta clase. En la clase Iris-virginica, la red neuronal presenta 2 errores (4%) al clasificarlas como Iris-versicolor, mientras que LDA y QDA mantienen precisiones cercanas al 98%, y el Árbol de Decisión muestra una precisión del 94%. En general, los modelos logran una

clasificación robusta para Iris-setosa, mientras que las confusiones principales se concentran entre Iris-versicolor e Iris-virginica.

En general, LDA mostró el rendimiento promedio más alto en este conjunto de datos, seguido por QDA, las redes neuronales, Decision Tree y SVM. Aunque las diferencias en la *accuracy* media no son aparentes, es necesario evaluar si estas diferencias son estadísticamente significativas.

Cuadro 3: Comparación de la *accuracy* media y desviación estándar entre modelos

Modelo	Accuracy media	Desviación estándar
LDA	0.980	$3,22 \times 10^{-2}$
QDA	0.973	$4,66 \times 10^{-2}$
Decision Tree	0.960	$5,62 \times 10^{-2}$
SVM	0.953	$6,32 \times 10^{-2}$
NN	0.974	$2,85 \times 10^{-2}$

En la Tabla 3 se observa que LDA alcanza la mayor precisión media (0.980), seguido de la red neuronal y QDA, mientras que SVM muestra la precisión promedio más baja y la mayor variabilidad.

Para evaluar si estas diferencias son estadísticamente significativas, se aplicó el test de Kruskal-Wallis sobre las distribuciones de *accuracy* de los modelos. Se obtuvo un p-valor de 0.8188, lo que indica que no existen diferencias significativas entre los modelos ($p > 0.05$).

5.4.3. Selección del mejor modelo para la resolución del problema

El test de Kruskal-Wallis mostró que no existen diferencias estadísticamente significativas en la *accuracy* entre LDA, QDA, Decision Tree, SVM y NN, aunque SVM presentó la media más baja y la mayor variabilidad, por lo que se descarta como la mejor opción. Entre los modelos restantes, LDA ofrece la mayor precisión media y la menor desviación estándar, combinando además baja complejidad computacional y estabilidad en conjuntos de datos pequeños. Por tanto, se concluye que LDA es la mejor opción para este análisis, al lograr un equilibrio óptimo entre eficiencia, robustez y simplicidad.

6 QSAR biodegradation dataset

6.1. Fase 0: Exploración inicial de los datos

Se han generado diagramas de caja para visualizar la distribución de las variables cuantitativas y diagramas de barras para las variables cualitativas.

6.1.1. Distribución de las variables

Las variables cuantitativas del dataset QSAR han sido visualizadas mediante diagramas de caja en la Figura 6. Estos diagramas permiten identificar la distribución de los datos, así como la presencia de valores atípicos.

La mayoría de las variables presentan una cantidad significativa de valores atípicos (puntos rojos fuera de los bigotes del diagrama). Esto indica que los datos contienen valores extremos que podrían requerir tratamiento en el preprocesamiento. Por ejemplo: SpMax_L, SdssC, HyWi_m, LOC, SpMAX_B(m) y SM6_m.

Algunas variables también muestran una asimetría evidente, lo que sugiere que su distribución no es normal. Ejemplos claros de esto son: sdO, Ti2_L y C %, las cuales presentan una distribución altamente sesgada con valores extremos en un solo lado.




Figura 6: Diagramas de caja de las variables cuantitativas del dataset QSAR.

La Figura 7 presenta diagramas de barras para las variables cualitativas del dataset QSAR. Este tipo de visualización permite observar la frecuencia de las categorías en cada variable.

La mayoría de las variables presentan distribuciones altamente sesgadas, con valores concentrados en un número reducido de categorías. Variables como nHM, nCp, nCRX3, nN y nX tienen gran cantidad de muestras pertenecientes a la categoría más baja.

Otras variables como F04[C-N], F03[C-O] y C-026, tienen valores más dispersos, aunque siguen mostrando una concentración fuerte en los valores más bajos.

Para la variable a predecir, se observa que hay un posible desbalance en la distribución, con más ejemplos en una categoría NRB que en RB, lo que se puede ver reflejado en el desempeño de modelos de clasificación.




Figura 7: Histogramas de las variables cualitativas del dataset QSAR.

6.1.2. Matriz de correlación




Figura 8: Matriz de correlaciones QSAR.

Como vemos en la Figura 8, la mayoría de las celdas en la matriz presentan valores cercanos a 0 (colores verdes y amarillos), lo que indica que muchas variables no están fuertemente relacionadas entre sí.

Se observa que las correlaciones positivas más altas (en tonos rojo oscuro) se presentan entre las variables SpMax_A con SpMax_B(m) y Psi_i_A. Además, F04[C-N] y F02[C-N] muestran también una relación fuerte, lo que sugiere que ambas variables podrían estar capturando información similar sobre la estructura química de los compuestos.

En cuanto a las correlaciones negativas (en azul), se identifican relaciones destacadas entre nN-N y nO, así como entre nCIR y nArNO2. Estos valores negativos sugieren que cuando una de estas variables aumenta, la otra tiende a disminuir.

6.2. Fase 1: Preprocesado de datos

6.2.1. Datos atípicos

Se identificaron valores atípicos en múltiples variables utilizando el método de detección basado en cuartiles. Las variables con valores extremos incluyen:

SpMax_L	J_Dz(e)	HyWi_B(m)
LOC	SM6_L	SpPosA_B(p)
Psi_i1d	TF2_L	SpMax_B(m)
Psi_iA	SM6_B(m)	

Para minimizar el impacto de estos valores extremos sin eliminar información relevante, los valores atípicos fueron reemplazados por la mediana de la variable correspondiente.

6.2.2. Normalización

Dado que las variables predictoras presentan escalas distintas, se realizó una normalización de las variables cuantitativas utilizando el método Z-score.

Esta normalización se llevó a cabo dentro de cada iteración de validación cruzada para evitar la fuga de datos (*data leakage*).

6.3. Fase 2: Aprendizaje

En esta fase, se configuraron y entrenaron los modelos de Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), distintos árboles de decisión, máquinas de vectores soporte (SVM) y redes neuronales (NN) en el dataset QSAR Biodegradation, utilizando validación cruzada con 10 folds para evaluar su rendimiento.

6.3.1. Configuración del método de aprendizaje

Para la clasificación de compuestos biodegradables (RB) y no biodegradables (NRB) en el dataset QSAR, se aplicaron los siguientes modelos:

- **Discriminante Lineal de Fisher (LDA):** Asume covarianzas iguales entre clases y genera fronteras lineales. Se utilizó en su configuración estándar, sin ajuste adicional de hiperparámetros.
- **Discriminante Pseudo-Cuadrático (QDA):** Variante regularizada del QDA estándar, adecuada para manejar la varianza cero detectada en algunas variables de la clase RB.
- **Árbol de Decisión:** Se entrenaron 27 modelos variando tres hiperparámetros clave: profundidad máxima ($MaxDepth = 10, 30, 50$), tamaño mínimo de las hojas ($MinLeafSize = 1, 5, 10$) y tamaño mínimo del nodo padre ($MinParentSize = 2, 10, 20$).
- **Máquinas de Vectores Soporte (SVM):** Se evaluaron nueve configuraciones, combinando tres kernels (*lineal*, *gaussiano*, *polinómico*) con tres valores del parámetro de penalización $C = \{1, 3, 5\}$. Se realizaron tres repeticiones independientes para robustecer las estimaciones.
- **Redes Neuronales (Neural Networks):** Se implementaron redes neuronales de una sola capa oculta (*single layer perceptron*) con distintas configuraciones, combinando tres tamaños de capa oculta (5, 10, 15 neuronas) y dos algoritmos de entrenamiento (*trainscg* y *trainlm*). Las etiquetas binarias fueron codificadas mediante *one-hot encoding* para facilitar el aprendizaje supervisado, y se utilizó validación cruzada con 10 folds repetida tres veces para evaluar el rendimiento medio y la estabilidad.

6.3.2. Selección del método de estimación del error real

Se utilizó validación cruzada estratificada con $K=10$ folds, garantizando la preservación de la proporción de clases en cada partición. En el caso de las SVM y las redes neuronales, este procedimiento se repitió tres veces, permitiendo evaluar la estabilidad de las métricas frente a variaciones de la partición.

6.3.3. Elección de las métricas de evaluación

Se calcularon las métricas de *Accuracy*, *Recall*, *Specificity*, *Precision* y *F1-score* para cada fold. Dado el desbalance de clases presente en el dataset, se consideró el *F1-score* como la métrica principal para la selección del mejor modelo, al balancear precisión y exhaustividad en la identificación de la clase minoritaria.

6.3.4. Entrenamiento y obtención de resultados

Los modelos fueron entrenados y evaluados utilizando validación cruzada de la siguiente manera:

1. Se dividió el dataset en 10 subconjuntos de igual tamaño.

2. Se entrenó el modelo con 9 folds y se probó en el fold restante.
3. Se registraron las predicciones y se construyó la matriz de confusión.
4. Se repitió el proceso hasta que cada fold fuera utilizado como conjunto de prueba.
5. Se calcularon las métricas de evaluación promediando los resultados de los 10 folds.

Los resultados obtenidos se presentarán en la siguiente sección, donde se compararán los modelos en términos de precisión y otras métricas de rendimiento.

6.4. Fase 3: Análisis de resultados y comparación de modelos

En esta sección se presentan los resultados obtenidos para los modelos Discriminante Lineal de Fisher (LDA), Discriminante Cuadrático (QDA), Árboles de Decisión, Máquinas de Vectores de Soporte (SVM) y Redes Neuronales (NN) en el dataset QSAR biodegradation. Se analizan las métricas de evaluación obtenidas en cada caso, se comparan los modelos mediante pruebas estadísticas no paramétricas y se selecciona el modelo más adecuado para resolver la tarea de clasificación.

6.4.1. Resultados de clasificación

En la Tabla 4 se presentan los resultados promedio y desviación estándar para las seis configuraciones de redes neuronales (*Neural Networks*) evaluadas en el dataset QSAR. En esta ocasión, se añadió un conjunto de validación en el entrenamiento de cada red, lo cual permitió reducir el sobreajuste observado en versiones anteriores.

Cuadro 4: Resultados de las configuraciones de Redes Neuronales en el dataset QSAR

Parámetros			Métricas				
Modelo	Neurons	Algoritmo	Accuracy	Recall	Precision	Specificity	F1-score
NN 1	5	trainscg	$0,841 \pm 3,89 \times 10^{-2}$	$0,756 \pm 7,30 \times 10^{-2}$	$0,775 \pm 7,03 \times 10^{-2}$	$0,885 \pm 4,70 \times 10^{-2}$	$0,763 \pm 5,67 \times 10^{-2}$
NN 2	10	trainscg	$0,842 \pm 4,76 \times 10^{-2}$	$0,727 \pm 1,15 \times 10^{-1}$	$0,785 \pm 8,98 \times 10^{-2}$	$0,901 \pm 4,22 \times 10^{-2}$	$0,750 \pm 1,01 \times 10^{-1}$
NN 3	15	trainscg	$0,850 \pm 3,54 \times 10^{-2}$	$0,757 \pm 9,94 \times 10^{-2}$	$0,793 \pm 5,36 \times 10^{-2}$	$0,898 \pm 3,28 \times 10^{-2}$	$0,771 \pm 6,24 \times 10^{-2}$
NN 4	5	trainlm	$0,865 \pm 4,25 \times 10^{-2}$	$0,785 \pm 7,93 \times 10^{-2}$	$0,813 \pm 7,68 \times 10^{-2}$	$0,906 \pm 4,52 \times 10^{-2}$	$0,797 \pm 6,59 \times 10^{-2}$
NN 5	10	trainlm	$0,869 \pm 3,09 \times 10^{-2}$	$0,774 \pm 6,42 \times 10^{-2}$	$0,830 \pm 6,42 \times 10^{-2}$	$0,917 \pm 3,57 \times 10^{-2}$	$0,799 \pm 4,76 \times 10^{-2}$
NN 6	15	trainlm	$0,872 \pm 3,52 \times 10^{-2}$	$0,777 \pm 8,64 \times 10^{-2}$	$0,837 \pm 6,37 \times 10^{-2}$	$0,920 \pm 3,64 \times 10^{-2}$	$0,803 \pm 5,73 \times 10^{-2}$

Para evaluar si existían diferencias significativas entre las configuraciones de SVM en el dataset QSAR, se aplicó el test no paramétrico de Kruskal-Wallis sobre las métricas de *accuracy*, *recall*, *specificity*, *precision* y *F1-score*.

Los modelos entrenados con el algoritmo *trainlm* mostraron un rendimiento más robusto en términos globales. En particular, la configuración con 15 neuronas ocultas (**NN 6**) obtuvo las mejores puntuaciones promedio en *accuracy*, *precision*, *specificity* y *F1-score*. Las redes entrenadas con *trainscg*, si bien competitivas, mostraron una mayor variabilidad entre repeticiones y resultados ligeramente inferiores en las métricas principales.

Los resultados del test de Kruskal-Wallis no revelaron diferencias estadísticamente significativas entre las configuraciones de redes neuronales en ninguna de las métricas evaluadas. Esto indica que todas las configuraciones alcanzan un rendimiento comparable dentro de la variabilidad esperada. Teniendo esto en cuenta se selecciona la configuración que usa el algoritmo *Scaled Conjugate Gradient* y 5 neuronas en la capa oculta (**NN1**) por su mayor simplicidad y eficiencia computacional.

6.4.2. Comparación entre modelos

En esta sección se comparan los mejores modelos de LDA, QDA, Árbol de Decisión, SVM y Redes Neuronales en términos de *accuracy*, *recall*, *precision*, *specificity* y *F1-score*, aplicando

pruebas de Kruskal-Wallis para detectar diferencias globales, seguidas de comparaciones múltiples con corrección de Bonferroni.

Cuadro 5: Métricas (media y desviación estándar) para los modelos evaluados en QSAR

Modelo	Accuracy	Recall	Specificity	Precision	F1-score
LDA	$0,8417 \pm 3,82 \times 10^{-2}$	$0,7573 \pm 8,41 \times 10^{-2}$	$0,8880 \pm 4,09 \times 10^{-2}$	$0,7748 \pm 7,05 \times 10^{-2}$	$0,7620 \pm 4,75 \times 10^{-2}$
QDA	$0,8474 \pm 3,07 \times 10^{-2}$	$0,7543 \pm 7,63 \times 10^{-2}$	$0,8981 \pm 3,37 \times 10^{-2}$	$0,7899 \pm 5,86 \times 10^{-2}$	$0,7678 \pm 3,43 \times 10^{-2}$
Decision Tree	$0,8018 \pm 4,95 \times 10^{-2}$	$0,6811 \pm 9,38 \times 10^{-2}$	$0,8666 \pm 6,94 \times 10^{-2}$	$0,7289 \pm 1,13 \times 10^{-1}$	$0,6957 \pm 6,62 \times 10^{-2}$
SVM	$0,8701 \pm 3,71 \times 10^{-2}$	$0,7861 \pm 6,21 \times 10^{-2}$	$0,9127 \pm 4,01 \times 10^{-2}$	$0,8249 \pm 7,35 \times 10^{-2}$	$0,8035 \pm 5,57 \times 10^{-2}$
NN	$0,8414 \pm 3,89 \times 10^{-2}$	$0,7564 \pm 7,30 \times 10^{-2}$	$0,8846 \pm 4,70 \times 10^{-2}$	$0,7747 \pm 7,03 \times 10^{-2}$	$0,7628 \pm 5,67 \times 10^{-2}$

Se encontraron diferencias significativas en **accuracy** ($p = 0.0321$) y **F1-score** ($p = 0.0105$), mientras que no se hallaron diferencias significativas en **recall** ($p = 0.0666$), **precision** ($p = 0.3641$) ni **specificity** ($p = 0.6065$).




Figura 9: Comparaciones múltiples para Accuracy entre LDA, QDA, Árbol de Decisión, SVM y NN

En la Figura 9 se observa que las diferencias en *accuracy* son significativas únicamente entre la Red Neuronal y el Árbol de Decisión, siendo el rendimiento de NN estadísticamente superior. No se encontraron diferencias significativas entre NN, SVM, LDA y QDA en esta métrica.




Figura 10: Comparaciones múltiples para F1-score entre LDA, QDA, Árbol de Decisión, SVM y NN

La Figura 10 muestra las comparaciones múltiples para **F1-score**. Aquí también se identifican diferencias estadísticamente significativas entre la Red Neuronal y el Árbol de Decisión, lo que sugiere una ventaja del modelo NN en la capacidad de equilibrar precisión y sensibilidad. No obstante, las diferencias con los modelos SVM, LDA y QDA no son significativas.




Figura 11: Boxplot del *F1-score* para los distintos modelos comparados

6.4.3. Selección del mejor modelo para la resolución del problema

El análisis estadístico evidenció diferencias significativas en **F1-score** y **accuracy** entre los modelos evaluados, destacando tanto las **Redes Neuronales** como las **Máquinas de Vectores Soporte (SVM)** frente al Árbol de Decisión, cuyo rendimiento fue consistentemente inferior. No obstante, entre los modelos mejor posicionados —NN, SVM, LDA y QDA— no se observaron diferencias estadísticamente significativas en la mayoría de métricas evaluadas.

En consecuencia, y aplicando el principio de parsimonia, se selecciona como modelo final el **Discriminante Lineal de Fisher (LDA)**, por ser el método más sencillo y computacionalmente eficiente entre aquellos con desempeño estadísticamente equivalente. LDA ofrece una interpretación directa, estabilidad en la clasificación y un rendimiento comparable al de modelos más complejos, lo que lo convierte en una opción robusta y práctica para la clasificación de compuestos biodegradables en el dataset QSAR.

7 Henon dataset

7.1. Fase 0: Exploración inicial de los datos

Para analizar la dinámica de la serie Henon, se seleccionaron 1.500 muestras consecutivas extraídas aleatoriamente de un total de 300.000. La serie fue visualizada representando sus últimas 50 observaciones, mostrando oscilaciones complejas características de sistemas caóticos.

NumMissing	Min	Median	Max	Mean	Std
0	-1.2817	0.4095	1.2729	0.2578	0.7207

Cuadro 6: Estadísticas descriptivas de las 1500 muestras de la serie Henon

7.1.1. Distribución de las variables

Se realizó un gráfico de líneas con puntos (ver Figura 12), que evidenció la variabilidad y los cambios abruptos de la serie, sugiriendo la necesidad de emplear métodos capaces de capturar no linealidades.




Figura 12: Últimos 50 valores de la serie Henon.

7.2. Fase 1: Preprocesado de datos

7.2.1. Generación de conjuntos de datos

Se generaron dos conjuntos de datos a partir de la serie Henon utilizando ventanas deslizantes de tamaño 5 y 10. Cada conjunto se dividió en entradas (INPUTS) y salidas (OUTPUTS) para las tareas de predicción.

Conjunto	Entradas (filas $\times$ columnas)	Salidas (filas $\times$ columnas)
Ventana 5	1495 $\times$ 5	1495 $\times$ 1
Ventana 10	1490 $\times$ 10	1490 $\times$ 1

Cuadro 7: Dimensiones de los conjuntos de datos generados con ventanas de tamaño 5 y 10.

7.3. Fase 2: Aprendizaje

7.3.1. Configuración del método de aprendizaje

Se entrenaron modelos de **Redes Neuronales** para tareas de regresión, combinando dos algoritmos de entrenamiento (*trainscg* y *trainlm*) con tres configuraciones de neuronas ocultas (5, 10 y 15). Esta combinación generó un total de seis arquitecturas distintas.

7.3.2. Selección del método de estimación del error real

Se utilizó validación cruzada K-fold ($K = 10$) repetida tres veces. En cada repetición, los datos se dividieron aleatoriamente en 10 subconjuntos, entrenando el modelo con nueve de ellos y evaluando en el restante. Este procedimiento permitió estimar métricas de error promedio y su variabilidad.

7.3.3. Elección de las métricas de evaluación

El rendimiento de las redes neuronales se evaluó utilizando las siguientes métricas de regresión, calculadas sobre los datos no normalizados:

- **MSE (Mean Squared Error)**: Promedio de los cuadrados de los errores, penaliza fuertemente las desviaciones grandes.
- **RMSE (Root Mean Squared Error)**: Raíz cuadrada del MSE, mantiene las unidades originales de la variable objetivo.
- **MAE (Mean Absolute Error)**: Promedio del valor absoluto de los errores, proporciona una medida más robusta frente a valores atípicos.

Estas métricas permiten cuantificar el error entre las predicciones y los valores reales, proporcionando una visión global del rendimiento del modelo.

7.3.4. Entrenamiento y obtención de resultados

Los modelos de red neuronal se entrenaron y evaluaron siguiendo los pasos:

1. Dividir los datos en entrenamiento y prueba según el esquema K-fold.
2. Calcular parámetros de normalización Z-score en el conjunto de entrenamiento y aplicarlos al conjunto de prueba.
3. Entrenar la red neuronal sobre el conjunto de entrenamiento utilizando el algoritmo seleccionado.
4. Realizar predicciones sobre el conjunto de prueba.
5. Calcular métricas de error (MSE, RMSE, MAE) para cada fold y repetición.

Al finalizar, se calcularon medias y desviaciones estándar de cada métrica, lo que permitió comparar de forma robusta el rendimiento entre diferentes configuraciones de redes.

7.4. Fase 3: Análisis de resultados y comparación de modelos

Redes Neuronales con tamaño de ventana 5

7.4.1. Resultados de regresión ($d = 5$)

La Tabla 8 resume los resultados obtenidos por las distintas configuraciones de redes neuronales en el dataset Henon con ventana $d = 5$. Las redes entrenadas con `trainlm` (NN 4–6) superan claramente a las que utilizan `trainscg`, con errores significativamente menores. Entre ellas, **NN 6** (15 neuronas, `trainlm`) alcanza el mejor rendimiento global, con un MSE de $1,0106 \times 10^{-9}$, consolidándose como el modelo más preciso.

Cuadro 8: Resultados de las configuraciones de Redes Neuronales en el dataset Henon ($d = 5$)

Parámetros			Métricas		
Modelo	Neurons	Algoritmo	MSE	RMSE	MAE
NN 1	5	trainscg	$8,6434 \times 10^{-3} \pm 1,4148 \times 10^{-3}$	$4,7760 \times 10^{-2} \pm 1,7911 \times 10^{-2}$	$3,5762 \times 10^{-2} \pm 1,4306 \times 10^{-2}$
NN 2	10	trainscg	$7,7211 \times 10^{-4} \pm 1,1815 \times 10^{-4}$	$2,3707 \times 10^{-2} \pm 4,6314 \times 10^{-3}$	$1,8715 \times 10^{-2} \pm 3,2482 \times 10^{-3}$
NN 3	15	trainscg	$5,9069 \times 10^{-4} \pm 8,6422 \times 10^{-4}$	$2,2333 \times 10^{-2} \pm 1,2925 \times 10^{-2}$	$1,7243 \times 10^{-2} \pm 9,6826 \times 10^{-3}$
NN 4	5	trainlm	$2,1606 \times 10^{-5} \pm 1,3870 \times 10^{-8}$	$9,7319 \times 10^{-4} \pm 5,4797 \times 10^{-5}$	$6,9227 \times 10^{-4} \pm 4,2679 \times 10^{-5}$
NN 5	10	trainlm	$3,0915 \times 10^{-9} \pm 3,7950 \times 10^{-2}$	$4,7142 \times 10^{-5} \pm 8,1519 \times 10^{-2}$	$3,6677 \times 10^{-5} \pm 5,7229 \times 10^{-2}$
NN 6	15	trainlm	$1,0106 \times 10^{-9} \pm 2,2484 \times 10^{-8}$	$2,7269 \times 10^{-5} \pm 6,8954 \times 10^{-5}$	$2,0720 \times 10^{-5} \pm 5,3569 \times 10^{-5}$

7.4.2. Comparación entre configuraciones de Redes Neuronales ($d = 5$)

El análisis estadístico reveló diferencias significativas entre configuraciones para las métricas **RMSE** y **MAE** ($p < 0.0001$ en ambos casos), mientras que no se detectaron diferencias significativas en **MSE** ($p = 0.1878$). Las comparaciones múltiples indicaron que las configuraciones NN3, NN4, NN5 y NN6 forman un grupo homogéneo, sin diferencias estadísticamente significativas entre ellas.




Figura 13: Comparaciones múltiples para RMSE entre configuraciones de NNs ($d = 5$).




Figura 14: Comparaciones múltiples para MAE entre configuraciones de NNs ($d = 5$).

Por tanto, considerando este empate estadístico y aplicando un criterio de parsimonia, se selecciona **NN4** (5 neuronas ocultas, algoritmo `trainlm`) como el modelo final. Esta configuración es la más simple entre las de mejor rendimiento, lo que favorece su estabilidad, interpretabilidad y eficiencia computacional.

Redes Neuronales con tamaño de ventana 10

7.4.3. Resultados de regresión ($d = 10$)

La Tabla 9 presenta los resultados de las seis configuraciones de redes neuronales entrenadas con una ventana de tamaño $d = 10$ sobre el dataset Henon. Se reportan las métricas de error MSE, RMSE y MAE con sus respectivas desviaciones estándar.

Cuadro 9: Resultados de las configuraciones de Redes Neuronales en el dataset Henon ($d = 10$)

Parámetros			Métricas		
Modelo	Neurons	Algoritmo	MSE	RMSE	MAE
NN 1	5	trainscg	$1,7617 \times 10^{-3} \pm 1,2987 \times 10^{-3}$	$3,4915 \times 10^{-2} \pm 1,4412 \times 10^{-2}$	$2,6478 \times 10^{-2} \pm 1,1253 \times 10^{-2}$
NN 2	10	trainscg	$1,1169 \times 10^{-3} \pm 2,1689 \times 10^{-8}$	$2,7697 \times 10^{-2} \pm 7,2437 \times 10^{-5}$	$2,1668 \times 10^{-2} \pm 5,5828 \times 10^{-5}$
NN 3	15	trainscg	$7,6046 \times 10^{-4} \pm 1,2004 \times 10^{-3}$	$2,5678 \times 10^{-2} \pm 1,5416 \times 10^{-2}$	$2,0146 \times 10^{-2} \pm 1,1444 \times 10^{-2}$
NN 4	5	trainlm	$3,2124 \times 10^{-4} \pm 1,7593 \times 10^{-3}$	$3,4009 \times 10^{-3} \pm 1,7900 \times 10^{-2}$	$2,4201 \times 10^{-3} \pm 1,2698 \times 10^{-2}$
NN 5	10	trainlm	$4,9546 \times 10^{-9} \pm 2,4963 \times 10^{-3}$	$5,8306 \times 10^{-5} \pm 2,3740 \times 10^{-2}$	$4,4804 \times 10^{-5} \pm 1,8246 \times 10^{-2}$
NN 6	15	trainlm	$2,8106 \times 10^{-8} \pm 1,2051 \times 10^{-8}$	$8,2969 \times 10^{-5} \pm 4,7284 \times 10^{-5}$	$6,4237 \times 10^{-5} \pm 3,6303 \times 10^{-5}$

En general, se observa que el rendimiento mejora al aumentar la complejidad del modelo, especialmente al usar el algoritmo **trainlm**. Las configuraciones NN5 y NN6 ofrecen los errores más bajos.

7.4.4. Comparación entre configuraciones de Redes Neuronales ($d = 10$)

Se realizó un análisis ANOVA para comparar las configuraciones de redes neuronales en términos de *MSE*, *RMSE* y *MAE*. Los resultados revelaron diferencias estadísticamente significativas en todas las métricas (*MSE*: $p = 0,0073$, *RMSE* y *MAE*: $p < 0,0001$).

Las Figuras 15, 16 y 17 muestran las comparaciones múltiples. Se observa que los modelos NN 4, NN 5 y NN 6 (entrenados con **trainlm**) presentan errores significativamente menores que NN 1 (entrenado con **trainscg** y 5 neuronas), especialmente en *RMSE* y *MAE*, mientras que las diferencias entre ellos no son significativas.




Figura 15: Comparaciones múltiples para MSE en $d = 10$ entre configuraciones de NNs.




Figura 16: Comparaciones múltiples para RMSE en $d = 10$ entre configuraciones de NNs.




Figura 17: Comparaciones múltiples para MAE en $d = 10$ entre configuraciones de NNs.

Dado que las configuraciones NN 4, NN 5 y NN 6 presentan un rendimiento estadísticamente equivalente, se recomienda seleccionar **NN 4** (5 neuronas, `trainlm`) como modelo final. Esta opción ofrece un rendimiento excelente con menor complejidad y riesgo de sobreajuste frente a redes más grandes.

7.5. Comparación entre modelos con diferentes tamaño de ventana

7.5.1. Comparación entre los dos mejores modelos NN

En esta sección se comparan los modelos NN4 seleccionados para los tamaños de ventana $d = 5$ y $d = 10$. Ambos modelos comparten la misma configuración de red neuronal (5 neuronas ocultas, algoritmo de entrenamiento `trainlm`), diferenciándose únicamente en el tamaño de la ventana utilizada para construir los conjuntos de entrenamiento.

Cuadro 10: Comparación entre las dos mejores configuraciones de NN con diferentes tamaños de ventana

Parámetros			Métricas		
Modelo	Neuronas	Algoritmo	MSE	RMSE	MAE
NN4 ($d = 5$)	5	<code>trainlm</code>	$2,1606 \times 10^{-5} \pm 1,3870 \times 10^{-8}$	$9,7319 \times 10^{-4} \pm 5,4797 \times 10^{-5}$	$6,9227 \times 10^{-4} \pm 4,2679 \times 10^{-5}$
NN4 ($d = 10$)	5	<code>trainlm</code>	$3,2124 \times 10^{-4} \pm 1,7593 \times 10^{-3}$	$3,4009 \times 10^{-3} \pm 1,7900 \times 10^{-2}$	$2,4201 \times 10^{-3} \pm 1,2698 \times 10^{-2}$

Para evaluar la significancia estadística de estas diferencias, se aplicó la prueba de Wilcoxon. Se obtuvieron resultados significativos para MSE y MAE ($p = 0,0488$ en ambos casos), mientras que la diferencia en RMSE no alcanzó significancia ($p = 0,0645$). Por tanto, el modelo entrenado con $d = 5$ es considerado globalmente superior, al mostrar menor error en todas las métricas y diferencias estadísticamente significativas en dos de ellas.

7.5.2. Selección del mejor modelo

El modelo seleccionado fue **NN4** (5 neuronas, algoritmo `trainlm`, ventana de tamaño 5), ya que presentó el menor error medio y la menor desviación estándar en comparación con el resto de configuraciones. Su desempeño fue significativamente superior frente al mismo modelo con tamaño de ventana $d = 10$, con diferencias estadísticamente significativas en las métricas MSE y MAE ($p = 0,0488$ en ambos casos), confirmadas mediante la prueba de Wilcoxon.

En la Figura 18 se muestra la comparación entre los valores reales y predichos para las últimas 50 muestras utilizando esta red neuronal. Se observa un ajuste preciso incluso en las regiones más variables de la serie, lo que evidencia la capacidad del modelo para aprender y generalizar la dinámica del sistema Henon.




Figura 18: Últimos 50 valores: Real vs. Predicho (NN4, ventana 5)

7.5.3. Comparación entre el mejor modelo SVM y el mejor modelo NN

Finalmente, se compararon los dos modelos con mejor rendimiento en el dataset Henon con tamaño de ventana $d = 5$: el modelo **SVM 4** (kernel gaussiano, $C = 1$) y el modelo **NN 4** (5 neuronas ocultas, algoritmo `trainlm`). La Tabla 11 muestra las métricas obtenidas por ambos modelos, incluyendo sus desviaciones estándar.

Cuadro 11: Comparación entre el mejor modelo SVM y NN ($d = 5$)

Métrica	SVM 4	NN 4
MSE	$6,3787 \times 10^{-3} \pm 5,6567 \times 10^{-2}$	$2,1606 \times 10^{-5} \pm 1,3870 \times 10^{-8}$
RMSE	$7,9724 \times 10^{-2} \pm 4,3641 \times 10^{-3}$	$9,7319 \times 10^{-4} \pm 5,4797 \times 10^{-5}$
MAE	$6,7315 \times 10^{-2} \pm 3,6611 \times 10^{-3}$	$6,9227 \times 10^{-4} \pm 4,2679 \times 10^{-5}$

La prueba de Wilcoxon aplicada sobre los errores obtenidos en los 10 folds confirma la existencia de diferencias estadísticamente significativas para las tres métricas ($p = 0.0020$ en todos los casos), favoreciendo claramente al modelo de red neuronal.

En consecuencia, se selecciona **NN 4** como el mejor modelo final para el problema de regresión sobre la serie de Henon. Este modelo no solo presenta errores significativamente más bajos, sino que además mantiene una configuración simple (solo 5 neuronas), lo que lo convierte en una solución precisa, eficiente y robusta.

8 Discusión y Conclusiones

8.1. Discusión

En esta práctica se ha evaluado el rendimiento de las Redes Neuronales (NN) en dos contextos diferenciados: clasificación multiclase y binaria sobre los datasets Iris y QSAR, y predicción regresiva en la serie caótica de Henon. En todos los casos se analizaron múltiples configuraciones, variando el número de neuronas ocultas y el algoritmo de entrenamiento, y se aplicaron métodos de validación cruzada junto con análisis estadísticos para garantizar la robustez de las comparaciones.

En el caso del dataset **Iris**, todas las configuraciones de NN lograron una precisión elevada (accuracy >96 %), sin encontrarse diferencias estadísticamente significativas entre ellas según el test de Kruskal-Wallis ($p = 0.6067$). La red NN2 (10 neuronas, *trainscg*) presentó las mejores métricas promedio, pero se seleccionó NN1 (5 neuronas, *trainscg*) como modelo más adecuado entre las distintas Redes Neuronales por su simplicidad estructural y eficiencia, sin pérdida significativa de rendimiento. Aún así no se observaron diferencias estadísticamente significativas entre este y modelos más sencillos, por ello se selecciona finalmente **LDA** como el modelo más adecuado para este problema.

Para el dataset **QSAR biodegradation**, el rendimiento fue más variable entre configuraciones. Las redes entrenadas con *trainlm* mostraron en general mejores métricas de F1-score, recall y specificity, con NN6 (15 neuronas, *trainlm*) como la configuración con mejores resultados promedio. Sin embargo, dado que las diferencias frente a modelos más simples no fueron significativas en varias métricas clave, y atendiendo al principio de parsimonia, se seleccionó finalmente NN1 (5 neuronas, *trainscg*) como modelo más adecuado entre las distintas Redes Neuronales por su rendimiento competitivo y menor complejidad computacional. De todas formas, ocurre lo mismo que en Iris dataset, donde escogemos **LDA** al no haber diferencias estadísticamente significativas.

En el problema de **regresión sobre la serie de Henon**, se probaron seis configuraciones de NN para cada tamaño de ventana ($d = 5$ y $d = 10$). Los resultados mostraron que el uso del algoritmo *trainlm* resultó esencial para lograr errores bajos, con diferencias estadísticamente significativas en RMSE y MAE ($p < 0.0001$). Aunque NN6 (15 neuronas, *trainlm*) obtuvo los errores más bajos absolutos, el análisis post hoc reveló que **NN4 (tamaño de ventana 5, 5 neuronas, *trainlm*)** pertenecía al mismo grupo homogéneo de mejor rendimiento, por lo que se seleccionó como la mejor configuración por su simplicidad y estabilidad.

Además, la comparación de NN4 con ventana $d = 5$ frente a la misma configuración con $d = 10$ mediante el test de Wilcoxon reveló diferencias estadísticamente significativas en MSE y MAE ($p = 0.0488$), confirmando que la ventana más corta produce predicciones más precisas. Por último, se compararon los mejores modelos de NN y SVM sobre el conjunto Henon ($d = 5$), obteniendo el modelo NN4 errores significativamente inferiores en todas las métricas ($p = 0.0020$), confirmando su superioridad en este problema.

8.2. Conclusiones

- **Clasificación en el dataset Iris:** Todas las configuraciones de redes neuronales evaluadas alcanzaron una precisión superior al 96 %, sin encontrarse diferencias estadísticamente significativas entre ellas. Aunque NN1 (5 neuronas, *trainscg*) fue seleccionada como la mejor red por su simplicidad y rendimiento estable, se optó finalmente por LDA como modelo más adecuado, al no presentar diferencias significativas respecto a las NN y destacar por su interpretabilidad y eficiencia.
- **Clasificación en el dataset QSAR:** Las redes neuronales entrenadas con *trainlm* obtuvieron en general métricas superiores, siendo NN6 (15 neuronas, *trainlm*) la mejor en términos promedio. Sin embargo, las comparaciones múltiples no evidenciaron diferencias significativas con modelos más simples, por lo que, siguiendo el principio de parsimonia, se seleccionó LDA como el modelo final más apropiado.
- **Regresión sobre la serie de Henon:** El uso del algoritmo *trainlm* fue esencial para reducir los errores de predicción, con NN6 (15 neuronas, *trainlm*) alcanzando los valores absolutos más bajos. No obstante, se seleccionó NN4 (5 neuronas, *trainlm*, $d = 5$) como mejor modelo por formar parte del grupo de mejor rendimiento estadístico con menor complejidad estructural.
- **Influencia del tamaño de ventana en regresión:** La comparación entre NN4 con ventanas $d = 5$ y $d = 10$ reveló diferencias estadísticamente significativas en MSE y MAE ($p = 0,0488$), favoreciendo claramente el uso de ventanas más cortas en este problema de predicción de series temporales.
- **Comparación NN vs. SVM:** La comparación entre los mejores modelos con $d = 5$ (NN4 vs. SVM4) mostró una superioridad clara de la red neuronal en las tres métricas evaluadas (MSE, RMSE y MAE), con diferencias estadísticamente significativas ($p = 0,0020$). Esto sugiere que las redes neuronales, incluso con arquitecturas simples, son más adecuadas para modelar dinámicas no lineales complejas como la del sistema de Henon.
- **Valor del MAE como métrica:** A lo largo de las distintas fases de análisis, el MAE se ha demostrado como una métrica especialmente útil para la evaluación de modelos de regresión, por su interpretación directa como error medio absoluto y su robustez frente a valores extremos, en comparación con MSE y RMSE.